

# Conception et implémentation d'un compilateur pour le langage E

# 1 But de ces séances de travaux pratiques

Au cours de ces séances de travaux pratiques, vous allez réaliser un compilateur pour un petit langage de programmation, le langage E. Le langage E est un dérivé du langage C. Nous nous concentrerons d'abord sur la compilation d'un version basique du langage E que nous enrichirons par la suite sur les créneaux de projet. Votre compilateur sera composé d'un analyseur lexical (lexer), d'un analyseur syntaxique (parser), puis de plusieurs passes de compilation qui transformeront les programmes E dans des langages de plus en plus bas niveau, jusqu'à la génération de code assembleur RISC-V, qui seront finalement assemblés par des assembleurs existants et qui pourront être exécutés sur vos machines (en utilisant qemu).

Comme nous allons le voir, le langage E est relativement petit, pour vous permettre de le réaliser dans le temps de TP qui vous est imparti. Cependant, il permet d'illustrer un grand nombre de concepts fondamentaux de la compilation. Au cas où vous trouveriez que le langage est trop petit, ou bien que les passes de compilation et d'optimisation suggérées ne sont pas suffisantes, nous vous fournirons une liste d'améliorations possibles que vous pourrez implémenter.

La Section 2 vous présente l'architecture du compilateur que vous allez concevoir, notamment les structures de données à utiliser et les différents langages intermédiaires. La Section 3 vous présente l'infrastructure de test qui vous accompagnera pour débugger votre compilateur. Les sections suivantes décrivent le travail que vous aurez à faire lors des séances de TP. Le découpage en TP est donné à titre indicatif. Si vous n'avez pas fini le travail demandé à la fin d'un TP, vous pourrez utiliser un bout de la séance suivante pour le finir. Essayez de ne pas prendre *trop* de retard.

Vous trouverez le squelette associé à ce TP à l'adresse suivante :

https://gitlab-research.centralesupelec.fr/cidre-public/compilation/infosec-ecomp

Si vous voulez travailler sur ce projet dans un dépôt git pour partager votre code avec votre binôme, créez un dépôt vierge sur la plateforme de votre choix (un gitlab de CentraleSupélec, un github, autre chose), puis utilisez la procédure suivante :

```
$ git clone https://gitlab-research.centralesupelec.fr/cidre-public/compilation/infosec-ecomp
$ cd infosec-ecomp
$ git remote rename origin le-remote-d-origine
$ git remote add origin git@votre-nouveau-depot.com/.../votre-depot.git
```

Vous pourrez alors utiliser ce dépôt git normalement (commit / push / pull) comme vous avez l'habitude. Il pourra être pratique, pour que nous vous aidions, que vous nous donniez accès en lecture à votre dépôt git. Peut-être (comprendre *sûrement*) que nous modifierons le squelette au cours des séances de TP, notamment pour mettre à jour ce sujet. À ce moment là, nous vous préviendrons et il faudra committer vos changements sur votre propre dépôt git avant de faire :

```
$ git pull le-remote-d-origine master
```

Ce qui récupérera les changements que nous aurons poussés. (La plupart du temps, ce ne sera pas pour vous embêter mais pour vous fournir du code plus robuste et mieux documenté. Il n'est pas exclus qu'on vous donne un jour la solution du TP sans faire exprès et qu'on vous demande de ne pas la regarder.)



# 2 Organisation du compilateur

La figure 1 donne un aperçu de la structure du compilateur que vous allez réaliser. À partir d'un fichier source .e, l'analyseur lexical (ou lexer) générera un flux de lexèmes (ou tokens). Ce flux sera donné à l'analyseur syntaxique (ou parser) qui devra générer un arbre de syntaxe abstraite (Abstract Syntax Tree, ou AST). L'AST sera transformé dans une séquence de langages intermédiaires :

- un programme E, qui simplement une représentation formelle, en OCaml, du programme source;
- un programme CFG (Control-Flow Graph);
- un programme RTL (Register Transfer Language);
- un programme Linear;
- un programme LTL (Location Transfer Language);
- un programme Assembleur RISC-V.

Chacun de ces langages intermédiaire est détaillé dans le sujet de TP qui s'y rapporte, et est illustré sur l'exemple de la Figure 2a.

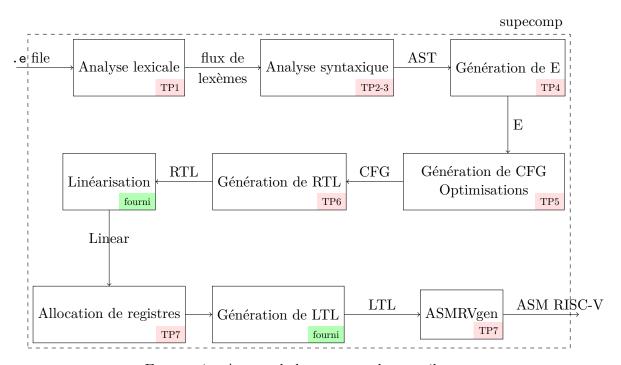


Figure 1 – Aperçu de la structure du compilateur

main

(b != 0)

```
else
                                      t = b
                                                return a
main(a,b){
  while(b != 0){
                                         b = (a \% b)
     t = b;
     b = a \% b;
     a = t;
                                             3
  return a;
                                                a = t
```

```
main(r0, r1):
main_2:
r2 <- 0
r1 != r2 ? jmp main_5
jmp main_1
main_3:
r0 <- r3
jmp main_2
main_5:
r3 <- r1
jmp main_4
main_4:
r4 <- %(r0, r1)
r1 <- r4
jmp main_3
main_1:
ret r0
```

(a) Programme E

}

}

- (b) CFG correspondant
- (c) Programme RTL

```
.global main
main:
                              main_5:
addi sp, sp, -8
                              mv s2, a1
                              remu s1, a0, a1
sd ra, 0(sp)
addi sp, sp, -8
                              mv a1, s1
sd s0, 0(sp)
                              mv a0, s2
addi sp, sp, -8
                              j main_2
sd s1, 0(sp)
                              main_6:
addi sp, sp, -8
                              mv sp, s0
sd s2, 0(sp)
                              ld s2, 0(sp)
mv s0, sp
                              addi sp, sp, 8
addi sp, sp, 0
                              ld s1, 0(sp)
main_2:
                              addi sp, sp, 8
li s1, 0
                              ld s0, 0(sp)
bne a1, s1, main_5
                              addi sp, sp, 8
                              ld ra, 0(sp)
j main_1
main_1:
                              addi sp, sp, 8
mv a0, a0
                              jr ra
j main_6
```

(d) Assembleur RISC-V

FIGURE 2 – Les différents langages intermédiaires utilisés lors de la compilation d'un programme



## 3 Tests

Vous trouverez dans le répertoire tests un ensemble d'outils vous permettant de tester votre compilateur. Les dossiers array, basic, char, funcall, globals, invader, ptr, type\_basic, type\_funcall et structs contiennent des programmes E vous permettant de tester les fonctionnalités correspondant au nom du dossier. Durant les séances de TP, nous nous concentrerons exclusivement sur les tests du dossier basic.

Lors des séances de projet, vous serez amenés à améliorer votre compilateur pour étendre son langage vers du C. Lors de ces extensions, vous pourrez utiliser les tests fournis dans les différents autres répertoires.

Pour chaque fichier test.e, nous vous avons fourni la sortie attendue avec les paramètres 1, 2 et 3 dans test.e.expect\_1\_2\_3 et avec les paramètres 14, 12, 3, 8 et 12 dans test.e.expect\_14\_12\_3\_8\_12. Vous pouvez tester que votre compilateur est conforme à ce qui est attendu en lançant make test depuis la racine de votre projet.

Les résultats des tests seront rassemblés dans le fichier tests/results.html que vous pouvez visualiser avec votre navigateur web préféré. Les résultats sont présentés sous forme de tableaux où les lignes correspondent aux programmes testés et les colonnes les résultats obtenus à différentes étapes de la compilation. Les noms des programmes sont cliquables pour avoir plus d'informations sur le déroulement de leur compilation, et leur exécution dans chacun des différents langages intermédiaires.

Pour tester les programmes individuellement vous pouvez utiliser le script tests/test.py ou directement le binaire produit (main.native) avec make :

```
# Commandes utiles
$ tests/test.py -f tests/basic/toto.e
$ tests/test.py -f tests/basic/*.e # équivalent à 'make test'
$ tests/test.py --help
$ ./main.native --help
```



# 4 TP1 : Analyseur lexical

Le but de cette séance de TP est de réaliser un analyseur lexical pour le langage E. Cette séance est l'occasion de mettre en œuvre l'algorithme vu en cours pour la réalisation d'un analyseur lexical. On vous rappelle qu'il repose sur l'utilisation d'un automate déterministe à états finis. Afin d'accélérer votre développement nous allons vous fournir une partie du code, et vous proposer une organisation de votre code.

## 4.1 Fonctions utiles de la librairie standard OCaml

La documentation complète est disponible en ligne sur : https://caml.inria.fr/pub/docs/manual-ocaml/libref

Par ailleurs, nous utilisons dans le squelette la librairie alternative **Batteries** (pour *OCaml*, batteries included, puisque la bibliothèque standard n'est parfois pas aussi complète qu'on pourrait le souhaiter).

Fonctions sur les listes : https://ocaml-batteries-team.github.io/batteries-included/hdoc2/BatList.html

- List.mem : vérifie si un élément appartient à une liste
- List.fold\_left : applique une fonction f à chaque élément d'une liste 1 en stockant le résultat dans acc
- List.map : applique une fonction à chaque élément d'une liste
- List.filter\_map : filtre les éléments d'une liste et applique une fonction aux éléments qui sont conservés.
- List.mem\_assoc : étant donnée une liste d'association (une liste dont les éléments sont des paires (k, v) où k correspond à une clé et v à une valeur), détermine si une clé est présente dans la liste.
- List.assoc\_opt : étant donnée une liste d'association, retourne la valeur associée à une clé (ou None si cette clé n'est pas définie)
- List.remove\_assoc : supprime les associations pour une clé donnée, dans une liste d'association
- List.iter : itère une fonction de type unit sur chaque élément d'une liste
- List.rev : renverse une liste (les premiers éléments deviennent les derniers)

Fonctions sur les ensembles **Set** : https://ocaml-batteries-team.github.io/batteries-included/hdoc2/BatSet.html

- Set.union: union de deux ensembles
- Set.add : ajout d'un élément à un ensemble
- Set.mem : vérifie si un élément appartient à un ensemble
- Set.empty : l'ensemble vide
- Set.is\_empty : vérifie si un ensemble est vide
- Set.singleton : construit un ensemble contenant un seul élément
- Set.fold : comme List.fold\_right, mais ici l'ordre des éléments ne peut pas être pris en compte (pas d'ordre dans un ensemble)
- Set.exists: vérifie s'il existe un élément d'un ensemble satisfaisait un prédicat.



Fonctions sur les tables de hachage <code>Hashtbl</code>: https://ocaml-batteries-team.github.io/batteries-included/hdoc2/BatHashtbl.html

- Hashtbl.find\_option : cherche la valeur associée à une clé dans une table de hachage.
- Hashtbl.replace : modifie ou crée une association clé/valeur dans une table de hachage.
- Hashtbl.create : crée une table de hachage vide
- Hashtbl.keys : la liste des clés pour lesquelles une association est connue dans une table de hachage

## 4.2 Tests

Pour tester le code des différentes fonctions de l'analyseur lexical, indépendamment du reste du compilateur, vous pouvez lancer la commande suivante, depuis la racine de votre projet :

```
$ make -C src test_lexer
make : on entre dans le répertoire «<PATH>/src»
ocamlbuild -use-ocamlfind test_lexer.native
Finished, 22 targets (22 cached) in 00:00:00.
./test_lexer.native
0: ([w]).(([h]).(([i]).(([l]).(([e]).(Eps)))))
1: ([i]).(([f]).(Eps))
→ ([ABCDEFGHIJKLMNOPQRSTUVWXYZabcdefghijklmnopqrstuvwxyz]).(([0123456789ABCDEFGHIJKLMNOPQRSTUVWXYZ_abcdefghij
==== NFA
States:
Initial states:
Final states :
[KO] epsilon_closure 1 : got , expected 1_2_3
[KO] epsilon_closure 2 : got , expected 2
[KO] epsilon_closure 3 : got , expected 2_3
[KO] epsilon_closure 4 : got , expected 4
[KO] dfa_initial_state : got , expected 1_2_3 \,
[KO] min_priority 1 : got None, expected Some (SYM_WHILE)
[KO] min_priority 2 : got None, expected Some (SYM_IDENTIFIER(bla))
[KO] min_priority 3 : got None, expected Some (SYM_WHILE)
[OK] min_priority 4
[KO] dfa states : got {{}}, expected {{1,2,3}, {2,4}, {2}}
dot -Tsvg /tmp/dfa.dot -o /tmp/dfa.svg
dot -Tsvg /tmp/nfa.dot -o /tmp/nfa.svg
make : on quitte le répertoire «<PATH>/src»
```

Cela a pour effet de compiler le fichier src/test\_lexer.ml et de le lancer. Ce fichier appelle les fonctions que vous définirez au fur et à mesure du TP dans src/lexer\_generator.ml et compare leur résultat avec le résultat attendu.

Ce test génère des graphes au format dot, puis les convertit en SVG pour les afficher d'une manière plus ou moins compréhensible par un humain. Si ce n'est pas déjà le cas, installez le paquet graphviz qui contient l'utilitaire dot. Le compilateur en aura par ailleurs besoin par la suite. Vous pouvez examiner les automates non-déterministe et déterministe générés en ouvrant les fichiers /tmp/nfa.svg et /tmp/dfa.svg, par exemple avec votre navigateur web.

Pour compiler et tester votre code au sein du compilateur, il suffit de lancer make test dans le répertoire racine de votre projet. Les résultats des tests sont stockés dans le fichier tests/results.html.



Résultats attendus sur un exemple :

```
$ cat tests/basic/just_a_variable_37.e
                                                         # À la fin du TP, results.html:
                                                         SYM_IDENTIFIER(main)
main(){
  just_a_variable = 37;
                                                         SYM_LPARENTHESIS
                                                         SYM_RPARENTHESIS
 return just_a_variable;
                                                         SYM_LBRACE
                                                         SYM_IDENTIFIER(just_a_variable)
                                                         SYM_ASSIGN
                                                         SYM_INTEGER(37)
                                                         SYM_SEMICOLON
# Au début du TP dans results.html:
                                                         SYM RETURN
Lexing error:
                                                         SYM_IDENTIFIER(just_a_variable)
Lexer failed to recognize string starting with
                                                         SYM_SEMICOLON
→ 'main(){
                                                         SYM_RBRACE
  just_a_var
                                                         SYM_EOF
```

Lorsque vous appelez make test, votre compilateur est lancé sur 38 fichiers de tests (les fichiers tests/basic/\*.e). Pour le moment, le fichiers tests/results.html indique que tous ces tests échouent à l'analyse lexicale puisque votre analyseur n'est pas encore écrit. Au fur et à mesure des séances de TP, ce fichier vous donnera de plus en plus d'information, notamment le résultat de l'analyse lexicale, syntaxique ainsi que le résultat de l'exécution de chacun des programmes de test à différents niveaux dans la chaîne de compilation. Cela sera un bon moyen de valider la correction de vos passes de compilation.

Vous pouvez aussi lancer le compilateur « à la main », c'est-à-dire sans passer par le make test :

```
$ make
$ ./main.native -f tests/basic/just_a_variable_37.e -show-tokens -
```

pour lancer le compilateur sur le fichier tests/basic/just\_a\_variable\_37.e et afficher les tokens reconnus. (Le « - » à la fin de la ligne de commande indique qu'on souhaite afficher les tokens sur la sortie standard. Si on veut les écrire dans un fichier, on remplacera ce « - » par le nom du fichier.)

## 4.3 Travail à effectuer

Le développement de notre analyseur lexical se déroule en trois étapes.

- 1. Premièrement, la spécification des expressions régulières permettant de reconnaître les termes du langage E.
- 2. Ensuite, un NFA (Non-deterministic Finite Automaton) pourra être généré pour ces expressions régulières.
- 3. Finalement, ce NFA sera transformé en DFA (*Deterministic Finite Automaton*) qui sera utile à l'analyseur pour reconnaître les termes du langage E et les associer au bon lexème.

Le travail que vous réaliserez au cours de cette séance se déroulera dans les fichiers src/lexer\_generator.ml et src/e\_regexp.ml.

## 4.3.1 Expressions régulières du langage E

Un premier travail est de donner à l'analyseur différentes expressions régulières permettant d'identifier les mots-clés et noms de variables du langage E. Pour vous familiariser avec le langage



E, n'hésitez pas à parcourir le répertoire tests/basic, où une trentaine d'exemples vous sont donnés.

Ouvrez le fichier src/e\_regexp.ml. On y définit le type des expressions rationelles (ou régulières) regexp. Les différents variants correspondent aux différentes constructions d'expressions régulières vues en cours. (À l'exception du variant Charset s, qui représente directement un caractère parmi un ensemble, plutôt que d'utiliser beaucoup de Alt (.,.), pour des raisons de praticité, et de performance.)

On y définit ensuite un alphabet, constitué de toutes les lettres minuscules et majuscules, les chiffres, ainsi qu'un certain nombre de symboles non-alphanumériques.

Ensuite vient la définition de  $list_regexp$ , la liste des expressions régulières, chacune correspondant à un lexème de notre langage E. Cette liste est de type (regexp \* (string -> token option)) list. Chaque élément de la liste est donc une paire (r,t) où r est une expression régulières (type regexp) et t est une fonction qui construit, à partir de la chaîne de caractère capturée par l'expression régulière, un lexème (type token). Pour les lexèmes de type token0 entre t0 entre t1 entre t2 entre t3 entre t4 entre t5 entre t6 entre t6 entre t7 entre t7 entre t8 entre t9 entre t

Un certain nombre d'expressions régulières associées à des lexèmes est déjà construit pour vous. Il vous reste à compléter cette liste pour un certain nombre de mots-clés (là où l'expression régulière **Eps** est utilisée, en attendant que vous ne complétiez le code).

Question 4.1. Compléter la fonction list\_regexp du fichier src/e\_regexp.ml en remplaçant les regex Eps par une expression régulière adéquate. À noter que la liste des lexèmes (type token) est disponible dans le fichier src/symbols.ml.

#### 4.3.2 Expressions régulières en NFAs

Nous souhaitons maintenant produire le NFA correspondant aux expressions régulières utilisées pour analyser le language.

Dans le fichier  $src/lexer\_generator.ml$ , le type nfa décrit ce qu'est un automate fini non-déterministe (NFA). Le champ  $nfa\_final$  est une liste de paires (q,t) où q est un état de l'automate, qui est déclaré comme étant final, et t est une fonction de type  $string \rightarrow token$  option (le même type que celui que l'on vient de voir dans le fichier  $src/e\_regexp.ml$ ). Cette fonction construit, lorsque c'est possible, un lexème à partir de la chaîne de caractères reconnue par l'automate.

Question 4.2. Écrire les fonctions cat\_nfa, alt\_nfa et star\_nfa du fichier src/lexer\_generator.ml. Ces fonctions permettent respectivement la concaténation, l'union et la répétion d'automates nfa.

Le type nfa est décrit et commenté au début du fichier.

Ces fonctions doivent reproduire la méthode de traduction des expressions rationelles en automates finis non-déterministes présentée en cours. La fonction  $\mathtt{star\_nfa}$  est paramétrée par une fonction t de type  $\mathtt{string} \to \mathtt{token}$  option, qui doit être associée à l'état final de l'automate construit.



Question 4.3. Compléter la fonction nfa\_of\_regexp qui produit un NFA à partir d'une expression régulière. Les différents paramètres de cette fonction sont décrits dans le squelette du TP.

Les cas Eps et Charset c sont donnés en exemple. Traiter les variantes restantes de regexp.

Vous pouvez tester votre implémentation ici en lançant, depuis le répertoire src :

## \$ make test\_lexer

Cela va afficher un certain nombre d'informations, la plupart n'étant pas pertinentes pour le moment. Le fichier "/tmp/nfa.dot" a du cependant être généré, ainsi qu'un fichier "/tmp/nfa.svg". Vous pouvez ouvrir ce dernier fichier et vous assurer que ce que vous visualisez correspond à ce que vous attendiez, pour la liste d'expressions régulières définie au début du fichier src/test\_lexer.ml, à savoir un NFA qui reconnaît les mots-clés if et while, ainsi que des identifiants.

#### 4.3.3 Déterminisation d'un NFA en DFA

Dans cette partie, on s'intéresse à transformer notre NFA en un DFA, qui permettra de construire notre analyseur lexical, en suivant les étapes décrites en cours. Le type dfa utilisé dans cette partie est défini et commenté dans le fichier src/lexer\_generator.ml.

Question 4.4. Compléter la fonction epsilon\_closure qui retourne l'ensemble des états accessibles par  $\varepsilon$ -transitions à partir d'un état d'un automate nfa.

Il faudra notamment écrire la fonction interne traversal (visited: nfa\_state set) (s: nfa\_state) : nfa\_state set, qui parcourt l'automate en ne suivant que les  $\varepsilon$ -transitions. Le paramètre visited de cette fonction contient l'ensemble des états déjà visités et s est l'état à partir duquel on souhaite commencer le parcours.

Les quelques tests relatifs à la fonction epsilon\_closure devraient afficher OK, après un make test\_lexer.

Question 4.5. Compléter la fonction epsilon\_closure\_set qui retourne l'ensemble des états accessibles par  $\varepsilon$ -transitions à partir d'un ensemble d'états d'un automate nfa.

Question 4.6. Ecrire la fonction dfa\_initial\_state qui construit l'état initial du DFA correspondant au NFA n.

Nous avons maintenant l'état initial de notre DFA. Nous allons désormais construire sa table de transition. Cette table est construite récursivement grâce à la fonction  $\mathtt{build\_dfa\_table}$ . Cette fonction prend en paramètre une table partiellement construite  $\mathtt{table}$ . Cette table est une table de hachage dont les clés sont des  $\mathtt{dfa\_state}$  et les valeurs sont des listes de paires (c,s) où c est un caractère de l'alphabet et s est l'état dans lequel on transite en lisant ce caractère. Les autres paramètres de la fonction sont  $\mathtt{n}$ , le NFA que l'on souhaite déterminiser, et  $\mathtt{ds}$ , l'état du DFA en cours de construction à partir duquel on souhaite ajouter des transitions.

Une partie du code de cette fonction vous est fournie. Si l'état ds a déjà été traité, on renvoie (), *i.e.* on ne fait rien; on a terminé! Dans le cas contraire, on doit calculer l'ensemble des transitions



possibles depuis cet état ds. La procédure de construction de ces transitions a été vue en cours, et est détaillée dans un commentaire au-dessus de cette fonction. Un certain nombre de fonctions auxiliaires, qui vous seront utiles, ont été définies pour vous.

Question 4.7. Construire l'expression transitions de la fonction build\_dfa\_table. Cette fonction permet de construire la table de transitions d'un dfa à partir d'un nfa. Les différentes étapes permettant de construire cette table de transitions sont spécifiées dans les commentaires situées au-dessus de la fonction.

Nous avons à présent l'état initial de notre DFA, ainsi que sa table de transitions. Il ne nous reste plus qu'à déterminer les états finaux, et notre DFA sera terminé!

Question 4.8. Compléter les fonctions min\_priority et dfa\_final\_states permettant de définir les états finaux de notre dfa. Les états finaux d'un dfa correspondent aux états qui contiennent au moins un état final d'un nfa. La fonction de conversion associée à un état final est obtenue en faisant usage de min\_priority. L'utilité de min\_priority est expliquée dans un commentaire du squelette.

Question 4.9. Compléter la fonction de transition make\_dfa\_step en utlisant la table de transition construite précédemment avec build\_dfa\_table. Cette fonction devrait être très simple, en se basant sur la table construite précédemment.

La fonction dfa\_of\_nfa, qui construit un DFA à partir d'un NFA, vous est offerte. Il s'agit simplement d'utiliser toutes les fonctions que vous avez écrites jusqu'à maintenant.

Vous pouvez à présent relancer make test\_lexer et observer le fichier /tmp/dfa.svg qui aura été généré. Cela devrait ressembler au DFA obtenu en toute fin de cours.

#### 4.3.4 Obtention de lexèmes à l'aide du DFA

Nous avons maintenant obtenu un DFA capable de reconnaître les mots-clés et variables du langage E. Nous souhaitons maintenant que notre DFA décompose les chaînes de caratères d'un programme E en une série de lexèmes/jetons définis dans le fichier src/symbols.ml.

Question 4.10. Complétez la fontion tokenize\_one. Celle-ci contient une fonction récursive recognize qui effectue des transitions dans le DFA tant que possible et retourne un jeton lorsqu'il aboutit.

Comme précédemment, de nombreux détails vous sont donnés dans les commentaires du fichier src/lexer\_generator.ml.

Note: vous aurez besoin de la fonction string\_of\_char\_list qui transforme un char list en string

Nous vous offrons les dernières étapes, à savoir

- la fonction tokenize\_all qui répète tokenize\_one tant qu'il y a des lexèmes à lire,
- la fonction tokenize\_file qui transforme un nom de fichier en la liste des lexèmes qui sont reconnus dans ce fichier,
- les morceaux de code dans main.ml qui appellent le lexer.

Si tout va bien, un make test maintenant vous affiche plein d'erreurs, mais de syntaxe seulement :-)



# 5 TP2: Analyseur syntaxique

Lors du TP précédent, vous avez écrit un analyseur lexical pour le langage E, et avez donc obtenu, à partir d'un fichier source .e un flux de lexèmes. Le but de ce TP est de construire un analyseur syntaxique. Pour ce faire, vous allez devoir écrire la grammaire du langage E dans un format spécifique et utiliser un générateur d'analyseur syntaxique.

# 5.1 ALPAGA: An LL(1) PArser GenerAtor

Il existe un certain nombre de générateurs d'analyseurs syntaxiques, les plus connus étant yacc (yet another compiler compiler) et bison (qui génèrent du code C), leur cousin ocamlyacc (qui génère du code Ocaml), menhir (qui génère aussi du code Ocaml, mais également du Coq!), ANTLR (ANother Tool for Language Recognition, écrit en Java et qui génère du Java, C\\$, python, JavaScript, Go, C++, et du Swift). Tous ces outils acceptent une grammaire en entrée, dans un format particulier, et produisent du code source qui parcourt le flux de lexèmes et produisent un arbre de syntaxe abstraite.

Afin d'avoir un contrôle fin sur le parser généré, et pour pouvoir exporter un certain nombre d'informations utiles lors de l'écriture de la grammaire, nous avons choisi de construire notre propre outil, et ainsi ajouter ALPAGA (An LL(1) PArser GenerAtor) au bestiaire des générateurs de parsers. ALPAGA est écrit en OCaml et produit du code OCaml (une version qui produit du C a aussi existé pour vos camarades de feu la majeure SIS) qui pourra être intégré à votre compilateur.

En plus du code de l'analyseur syntaxique, ALPAGA produit un fichier HTML qui contient un certain nombre d'informations intéressantes. Regardons par exemple la Figure 3, le fichier généré par une toute petite grammaire.

# Grammaire

# Table LL

(1)S	-> <u>EXPR</u> SYM_EOF			
(2) EXPR	-> <u>IDENTIFIER</u>			
(3)	-> <u>INTEGER</u>			
(4)	-> EXPR SYM_PLUS EXPR			
(5)	-> EXPR SYM_ASTERISK EXPR			
(6) INTEGER	-> SYM_INTEGER			
(7) IDENTIFIER -> SYM_IDENTIFIER				

(a) La grammaire (cliquable)

## **Table First**

Non-terminal	First
S	SYM_IDENTIFIER SYM_INTEGER
EXPR	SYM_IDENTIFIER SYM_INTEGER
INTEGER	SYM_INTEGER
IDENTIFIER	SYM_IDENTIFIER

(b) La relation First

	SYM_EOF	SYM_IDENTIFIER	SYM_INTEGER	SYM_PLUS	SYM_ASTERISK
S		1	1		
EXPR		<u>2 4 5</u>	<u>3 4 5</u>		
INTEGER			<u>6</u>		
IDENTIFIER		7			

(c) La table LL

FIGURE 3 – Fichier généré pour une petite grammaire d'expressions

On peut donc voir (Figure 3a) la grammaire que l'on a écrite, où chaque règle est numérotée, et chaque non-terminal de la grammaire est un lien vers l'ensemble des règles associées à ce non-

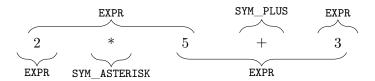


terminal. Cela paraît anecdotique pour cette toute petite grammaire, mais votre grammaire ne tiendra pas sur un seul écran et cette fonctionnalité sera alors très appréciée.

La Figure 3b donne pour chaque non-terminal, l'ensemble des terminaux qui peuvent commencer ce non-terminal. On voit que les non-terminaux S et EXPR acceptent un identifiant ou un entier, comme premier lexème. Des tables similaires existent pour les fonctions Null et Follow, vues en cours.

Finalement, la Figure 3c montre la table de prédiction qui va servir de matrice au parser généré. Chaque ligne correspond à un non-terminal que l'on souhaite parser. S est un nom classique pour désigner la règle de départ d'une grammaire, qu'on appelle l'axiome de la grammaire. Chaque colonne correspond à un terminal (lexème, token, symbole) qui vient du lexer. Si la case (NT, T) est vide, cela signifie que le non terminal NT ne peut pas commencer par le terminal T, autrement dit  $T \notin First(NT)$ . Si la case contient un numéro n, cela signifie qu'il faut appliquer la règle portant ce numéro. Si la case contient plusieurs numéros, il y a un conflit; notre grammaire est ambigüe.

Effectivement, comment doit-on analyser l'expression 2 \* 5 + 3?



Les deux dérivations sont conformes à la grammaire, mais donnent deux résultats différents : (2\*5)+3 d'un côté, qui vaut 13, et 2\*(5+3) de l'autre, qui vaut 16. Bien sûr, vous avez appris à l'école que l'addition est plus prioritaire que la multiplication et que c'est donc la première solution qui est la bonne. Pour expliquer cela à notre grammaire, comme vu en cours, il faut écrire la grammaire autrement, comme dans la figure 4. Dans la table LL (Figure 4c), les numéros de règle en bleu correspondent aux règles qui peuvent être appliqués car le terminal en question peut commencer ce non-terminal  $(t \in First(nt))$ ; les numéros en rouge correspondent aux règles qui peuvent être appliquées lorsque le non-terminal est nullable et que le terminal peut suivre ce non-terminal  $(Null(nt) \land t \in Follow(nt))$ .

Comme on le voit, la grammaire est plus compliquée à écrire, moins naturelle, mais non-ambigüe et la table générée est sans conflits.

## 5.1.1 Format de la grammaire

Voici le fichier de grammaire donné à ALPAGA pour l'exemple précédent.

tokens SYM\_EOF SYM\_IDENTIFIER<string> SYM\_INTEGER<int> SYM\_PLUS SYM\_ASTERISK non-terminals S EXPR TERM TERMS FACTOR FACTORS INTEGER IDENTIFIER axiom S

rules

S -> EXPR SYM EOF

IDENTIFIER -> SYM\_IDENTIFIER

INTEGER -> SYM\_INTEGER

EXPR -> TERM TERMS

TERM -> FACTOR FACTORS

TERMS -> SYM PLUS TERM TERMS

TERMS ->

FACTOR -> IDENTIFIER



## Grammaire

#### -> <u>EXPR</u> SYM\_EOF (2) EXPR -> TERM TERMS (3) TERM -> <u>FACTOR</u> <u>FACTORS</u> -> SYM\_PLUS <u>TERM</u> <u>TERMS</u> TERMS FACTOR -> IDENTIFIER -> INTEGER (8) FACTORS -> SYM ASTERISK FACTOR FACTORS 3 <--> SYM\_INTEGER (10) INTEGER (11) IDENTIFIER-> SYM\_IDENTIFIER

(a) La grammaire (cliquable)

# **Table First**

Non-terminal	First				
S	SYM_IDENTIFIER SYM_INTEGER				
EXPR	SYM_IDENTIFIER SYM_INTEGER				
TERM	SYM_IDENTIFIER SYM_INTEGER				
TERMS	SYM_PLUS				
FACTOR	SYM_IDENTIFIER SYM_INTEGER				
FACTORS	SYM_ASTERISK				
INTEGER	SYM_INTEGER				
IDENTIFIER	SYM_IDENTIFIER				

(b) La relation First

# Table LL

	SYM_E0F	SYM_IDENTIFIER	SYM_INTEGER	SUM_PLUS	SYM_ASTERISK
S		1	1		
EXPR		1 2 3	1 2 3		
TERM		<u>3</u>	<u>3</u>		
TERMS	<u>5</u>			4	
FACTOR		<u>6</u>	<u>7</u>		
FACTORS	9			9	8
INTEGER			<u>10</u>		
IDENTIFIER		11			

(c) La table LL

FIGURE 4 – Fichier généré pour une petite grammaire d'expressions

FACTOR -> INTEGER
FACTORS -> SYM\_ASTERISK FACTOR FACTORS
FACTORS ->

Le format du fichier est donc le suivant :

- Déclarations de terminaux (tokens). On déclare les terminaux qui vont être utilisés. Dans notre cas, il s'agira de l'ensemble des symboles (éléments du type token du fichier src/symbols.ml) générés au TP précédent. On place le mot clé tokens suivi de la liste des tokens. On peut donner plusieurs telles lignes.
  - À noter que pour les lexèmes non-constants (SYM\_IDENTIFIER et SYM\_INTEGER) on spécifie le type du paramètre entre chevrons : <string> ou <int>.
- Déclarations de non-terminaux. De manière similaire, on déclare la liste des non-terminaux que l'on va reconnaître, les uns à la suite des autres, après le mot-clé non-terminals.
- Déclaration de l'axiome de la grammaire : axiom S
- Le mot-clé rules. Cela délimite les déclarations de terminaux et non-terminaux de la suite du fichier.
- Une suite de règles, composées de :
  - un non-terminal
  - une flèche (->)
  - une suite (éventuellement vide) de terminaux et non-terminaux



Par exemple, la règle TERM -> FACTOR FACTORS signifie que le non-terminal TERM peut être reconnu en reconnaissant d'abord le non-terminal FACTOR, puis le non-terminal FACTORS. Autre exemple, la règle FACTORS -> signifie que le non-terminal FACTORS peut être reconnu par une suite vide de symboles.

## 5.1.2 Options d'ALPAGA

Le programme ALPAGA répond gentiment à l'option --help :

```
$ alpaga/alpaga --help
Usage:
    -g Input grammar file (.g)
    -t Where to output tables (.html)
    -pml Where to output the parser code (.ml)
    -help Display this list of options
    --help Display this list of options
$ alpaga/alpaga -g fichier-grammaire.g -t table.html -pml mon-parser.ml
```

Cela lira le fichier de grammaire fichier-grammaire.g et générera le code du parser dans mon-parser.ml. Une autre sortie du générateur est un fichier table.html. Ce fichier, que vous pouvez ouvrir dans un navigateur web, vous montrera votre grammaire dans un format cliquable, les tables Null, First et Follow nécessaires à la création du parser, et finalement la table LL obtenue. Notamment, les cellules de la table s'afficheront en fond rouge si un conflit a été détecté. Si tel est le cas, il faudra réécrire votre grammaire pour lever les ambiguïtés.

Note : Votre compilateur s'attend à trouver le parser généré dans le fichier src/generated\_parser.ml. Faites en sorte de ne pas le contrarier. (Ou plutôt : ne lancez pas ALPAGA à la main, le Makefile s'occupera de ça très bien pour vous.)

Le fichier expr\_grammar\_action.g contient un début de grammaire avec une règle qui comporte une action (du code entre accolades). Ignorez ce bout de code pour le moment, on y reviendra dans les questions suivantes.

Grammaire informelle de E. Afin de vous guider dans l'écriture de la grammaire du langage E, voici une grammaire informelle du langage.

- Un programme est constitué d'une liste de déclarations de fonctions (pour le moment, une seule fonction, qui doit s'appeler main).
- Une déclaration de fonction est composée du nom de la fonction suivi, entre parenthèse d'une liste d'arguments séparés par des virgules, suivi enfin du corps de la fonction.
- Le corps d'une fonction est composée d'instructions. Les instructions peuvent être :
  - un bloc d'instructions à l'intérieur d'accolades
  - une conditionnelle de la forme if (c) { i1 } else { i2 }, où c est une expression, et i1 et i2 sont des séquences d'instructions. La partie else est optionnelle.
  - une boucle de la forme while (c) i , où c est une expression, et i est une instruction.
  - une instruction return e; où e est une expression.
  - une instruction print (e); où e est une expression.
- Les expressions sont similaires à celles du C, où l'on se restreint aux opérateurs ==, !=, <, >, <=, >=, +, -, \*, /, %, ainsi que l'opérateur unaire -. Les expressions de base sont les entiers,



les identifiants de variables. On peut également parenthéser des sous-expressions. On pourra s'inspirer de la priorité des opérateurs du C  $^1$ .

Question 5.1. Complétez le fichier expr\_grammar\_action.g la grammaire pour le langage E, dans le format attendu par ALPAGA. Votre analyseur devrait consommer les lexèmes mais ne pas produire d'AST (vous n'avez rien fait pour cela encore).

Au fur et à mesure de l'écriture de votre grammaire, lancez make à la racine de votre projet et examinez le fichier grammar.html afin de vous assurer que vous n'introduisez pas de conflits.

Cet analyseur simple vous permettra de vous assurer que votre grammaire est correcte, indépendamment des actions que vous écrirez par la suite. Ainsi, sur un programme syntaxiquement correct, votre analyseur devrait réussir silencieusement. Pour un programme syntaxiquement incorrect, vous devriez obtenir une erreur de syntaxe.

Votre analyseur devrait réussir sur tous les fichiers .e présents dans le répertoire tests, à l'exception des fichiers syntax\_error\*.e. Plus précisément, la table du fichier tests/results.html devrait contenir une erreur de génération de E, et non plus une erreur de syntaxe.

À ce stade, vous savez donc reconnaître des programmes syntaxiquement valides, mais ne construisez pas d'arbre de syntaxe abstraite. Intéressons-nous maintenant à ce problème.

ALPAGA permet de spécifier, pour chaque règle de la grammaire, une **action**, *i.e.* une expression OCaml qui construit *quelque chose* pour cette règle. Par défaut, lorsqu'aucune action n'est explicitement spécifiée, l'action utilisée est () (la constante de type **unit**). Pour spécifier une action, il suffit d'ajouter à la fin de la ligne correspondant à une règle, du code OCaml entre accolades.

Regardons par exemple la grammaire, avec actions, ci-dessous :

```
tokens SYM_EOF SYM_IDENTIFIER<string> SYM_INTEGER<int> SYM_PLUS SYM_ASTERISK
non-terminals S EXPR TERM FACTOR INTEGER IDENTIFIER
non-terminals TERMS FACTORS
{
  let resolve_associativity term terms = ...
}
rules
S -> EXPR SYM_EOF { $1 }
IDENTIFIER -> SYM_IDENTIFIER { StringLeaf($1) }
INTEGER -> SYM_INTEGER { IntLeaf($1) }
EXPR -> TERM TERMS { resolve associativity $1 $2 }
TERM -> FACTOR FACTORS { resolve_associativity $1 $2 }
TERMS -> SYM_PLUS TERM TERMS { (Tadd, $2) :: $3 }
TERMS -> { [] }
FACTOR -> IDENTIFIER { $1 }
FACTOR -> INTEGER { $1 }
FACTORS -> SYM_ASTERISK FACTOR FACTORS { (Tmul, $2) :: $3 }
FACTORS -> { [] }
```

Quelques remarques sur cette grammaire:

<sup>1.</sup> https://en.cppreference.com/w/c/language/operator\_precedence



- On a inséré un bloc de code, entre accolades, juste avant la ligne 'rules'. Ce bloc de code sera inséré dans le code du parser généré, au tout début du fichier. On peut donc y définir des fonctions, importer des modules (open Symbols), qui seront utilisables dans les actions de la grammaire.
- Les règles pour les non-terminaux IDENTIFIER et INTEGER construisent des feuilles de l'arbre de syntaxe abstraite. Le type des arbres est défini dans src/ast.ml.
- On peut utiliser dans les actions des variables spéciales \$1, \$2, ... La variable \$i correspond au terme OCaml renvoyé par le *i*-ième élément de la règle. Concrètement, dans la règle :

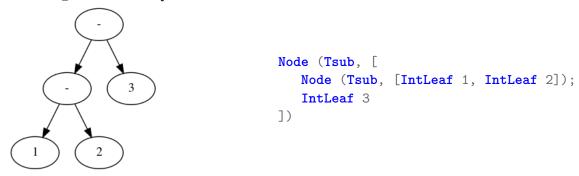
```
TERMS -> SYM_PLUS TERM TERMS { (Tadd, $2) :: $3 }
```

la variable \$2 correspond au résultat renvoyé par TERM et la variable \$3 correspond au résultat renvoyé par TERMS.

- Sur des terminaux, la variable \$i renvoie la chaîne de caractères qui a servi à reconnaître ce terminal. Utilisé notamment pour les terminaux SYM\_IDENTIFIER et SYM\_INTEGER qui sont respectivement de type string et int.
- Dans la règle EXPR -> TERM TERMS { resolve\_associativity \$1 \$2 }, on appelle une fonction sur les éléments produits par les non-terminaux TERM et TERMS. En regardant un peu les autres règles, on comprend qu'un appel à resolve\_associativity pourrait être effectué avec les paramètres :

```
resolve_associativity (IntLeaf(1)) [(Tsub, IntLeaf 2); (Tsub, IntLeaf 3)]
```

ce qui correspond à l'analyse syntaxique de la phrase 1-2-3. Le but de la fonction resolve\_associativity est de construire l'arbre suivant :



Question 5.2 (Action!). Ajouter des actions à votre grammaire afin de construire un AST similaire à celui montré ci-dessus. Référez-vous au fichier src/ast.ml qui documente le type des arbres de syntaxe abstraite.

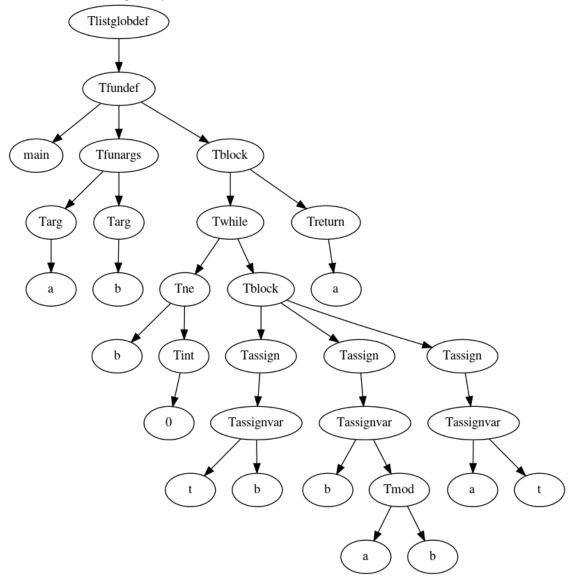
Il vous faudra notamment écrire le corps de la fonction resolve\_associativity, dont un squelette se trouve dans le fichier expr\_grammar\_action.g.

Quand vous aurez écrit les actions, pour tester, relancer make test depuis la racine de votre projet pour que :

- ALPAGA regénère le parseur dans le fichier src/generated\_parser.ml;
- tout le compilateur soit recompilé (wow!);
- les tests soient relancés.



Après cela, dans la table de tests/results.html, la page accessible depuis chaque lien correspondant à un nom de fichier devrait contenir un arbre de syntaxe abstraite (une représentation graphique de l'arbre que vous aurez construit). Ce qui devrait ressembler à cela (pour le programme de test tests/basic/gcd.e):





# 6 TP3: Génération et interprétation de programmes E

À partir de l'AST, vous allez maintenant devoir générer un programme E, et écrire un interpréteur pour ces programmes. La représentation OCaml des programmes E est définie dans le fichier elang.ml, décrit en cours.

Le fichier elang\_print.ml contient quelques fonctions d'affichage d'expressions, instructions et programmes E. Jetez-y un œil pour déboguer vos programmes.

#### 6.1 Génération de E

L'objectif est de générer un programme E à partir d'un AST. Les fonctions suivantes sont à compléter dans le fichier src/elang\_gen.ml.

Question 6.1. Écrivez la fonction make\_eexpr\_of\_ast (a: tree) : expr res qui transforme un sous-arbre a en une expression E. Cette fonction renvoie une erreur si l'arbre ne répond pas au format attendu.

Question 6.2. Écrivez la fonction make\_einstr\_of\_ast (a: tree) : instr res qui transforme un sous-arbre a en une instruction E. Cette fonction renvoie une erreur si l'arbre ne répond pas au format attendu.

Question 6.3. Complétez la fonction make\_fundef\_of\_ast (a: tree) : (string \* efun) res qui transforme un sous-arbre a en une définition de fonction E. Cette fonction renvoie une erreur si l'arbre ne répond pas au format attendu.

La fonction make\_eprog\_of\_ast (a: tree) : eprog res est déjà écrite. Elle transforme un sous-arbre a en un programme E. Cette fonction renvoie une erreur si l'arbre ne répond pas au format attendu.

## 6.2 Interprétation de E

Un moyen de vérifier que votre construction d'AST et transformation en E est correcte, est d'interpréter vos programmes, *i.e.* de les exécuter! Pour cela, vous allez écrire une fonction qui prend un programme E et une liste d'arguments, et qui rend la valeur retournée par ce programme.

Vous allez avoir besoin d'un état de programme : une structure de données qui mémorise la valeur de chaque variable tout au long de l'exécution de votre programme. Le fichier prog.ml contient notamment le type 'a state.

```
type 'a state = {
  env: (string, 'a) Hashtbl.t;
  mem: Mem.t
}
let init_state memsize =
  {
```



```
mem = Mem.init memsize;
env = Hashtbl.create 17;
```

Nous reviendrons sur la composante "mémoire" plus tard, lorsque l'on en aura besoin. Pour le moment, concentrons-nous sur l'environnement. Il s'agit d'une table de hâchage où les clés sont des noms de variables et les valeurs sont de type 'a. Dans un premier temps, on instanciera 'a avec int. Plus tard, on pourra enrichir avec le type des variables.

On utilisera donc les fonctions Hashtbl.replace : ('a, 'b) Hashtbl.t -> 'a -> 'b -> unit et Hashtbl.find\_option : ('a, 'b) Hashtbl.t -> 'a -> 'b option pour écrire et lire dans l'environnement.

Question 6.4 (Passage de paramètres). Dans la fonction eval\_eprog : (oc: formatter) (ep: eprog) (memsize : int) (params: int list) : int option res, construisez l'état initial du programme avec la liste d'arguments passés en paramètres. Notez que la liste ne contient que les valeurs; les noms des paramètres sont dans le programme lui-même (dans f.funargs).

Lancez votre compilateur avec l'option -e-run suivi des paramètres que vous voulez passer, et affichez l'état de votre programme pour vérifier que tout se passe bien.

Note : ignorez les paramètres superflus de la ligne de commande (par exemple, si votre programme attend 2 paramètres et que vous en fournissez 4, ignorez les deux derniers).

Passons maintenant à l'évaluation des expressions!

Question 6.5. Écrivez le corps des fonctions eval\_unop : unop -> int -> int et eval\_binop : binop -> int -> int -> int, qui prennent un opérateur (unaire ou binaire) et leurs paramètres entiers, et renvoient le résultat.

Question 6.6. Écrivez la fonction eval\_eexpr : int state -> expr -> int res qui évalue une expression e, étant donné un état s (de type int state).

Question 6.7. Écrivez la fonction eval\_einstr (oc: formatter) (st: int state) (ins: instr): (int option \* int state) res qui exécute l'instruction i avec l'état s.

Si l'instruction à exécuter contient un **return**, une valeur de retour peut être retournée : c'est la première composante du résultat (**int** option).

L'état peut évoluer, notamment lors d'affectations : la seconde composante du résultat (int state) donne le nouvel état.

Finalement, tout ça peut échouer (lecture d'une variable non initialisée), d'où le type res.

La fonction eval\_einstr est déjà appelée dans la fonction eval\_eprog, vous devriez donc avoir terminé cette partie du TP.



# 7 TP4 : Analyse de vivacité et élimination de code mort

L'objectif de cette séance est de programmer une optimisation pour notre compilateur : l'élimination des affectations mortes. Cette optimisation repose sur une analyse préalable du code du programme, qui sera facilitée par l'utilisation d'un langage intermédiaire approprié : CFG. Le langage CFG, utilise les mêmes expressions que le langage E, et un sous-ensemble des mêmes instructions. Les différences majeures sont les suivantes :

- un programme est un graphe de flot de contrôle (d'où le nom du langage : CFG pour Control Flow Graph);
- les instructions de branchement (IF et WHILE) sont encodées dans la structure du graphe directement.

Le langage CFG est décrit dans le fichier src/cfg.ml.

On y trouve notamment le type des expressions expr. Ce sont les mêmes expressions qu'en E. Cependant, lors des extensions de votre compilateur, les expressions E et les expressions CFG sont susceptibles d'évoluer différemment, c'est pourquoi nous avons préféré dupliquer ce type dès le début.

Une fonction CFG (type cfg\_fun) est composée d'une liste d'arguments (cfgfunargs), d'une table de hâchage des nœuds dont les clés sont les identifiants (entiers) des nœuds et la valeur associée est un cfg\_node, et le point d'entrée d'un CFG est l'identifiant d'un nœud particulier du CFG. Les instructions sur chaque nœud du CFG sont du type cfg\_node:

- Cassign(v,e,s) est une affectation v := e. s est l'identifiant du nœud successeur, *i.e.* à quel nœud doit-on sauter ensuite.
- **Creturn**(e) est un retour de fonction, en renvoyant la valeur de l'expression e. Cette instruction n'a pas de successeur.
- Cprint (e,s) affiche la valeur de l'expression e, puis continue l'exécution au nœud s.
- Ccmp(e, s1, s2) évalue l'expression e. Si sa valeur est vraie (pas zéro), alors l'exécution continue au nœud s1; sinon au nœud s2.
- Cnop s: n'effectue aucune opération, puis saute au nœud s.

Les fonctions succs et preds donnent respectivement les successeurs et les prédécesseurs d'un nœud dans un CFG.

Nous vous fournissons le code pour la passe de transformation qui génère un programme CFG à partir d'un programme E (cfg\_gen.ml), un interpréteur pour le langage CFG (cfg\_run.ml) ainsi qu'un afficheur pour les programmes CFG (cfg\_print.ml).

Vous pouvez utiliser l'afficheur en lançant votre compilateur comme suit :

```
$ ./main.native -f mon-fichier.e -cfg-dump mon-fichier.dot
$ dot mon-fichier.dot -Tpng -o mon-fichier.png
```

Vous pouvez utiliser l'interpréteur comme ceci :

```
$ ./main.native -f mon-fichier.e -cfg-run -- 4 12
```

La sortie du compilateur est un objet JSON qui donne des statistiques sur les différentes passes de compilation ("compstep") et exécutions ("runstep"). Dans notre cas, nous devrions trouver un champ "runstep": "CFG" qui contient un attribut "retval" (la valeur de retour du programme), un attribut "output" (la sortie du programme via la fonction print) et un attribut "error" qui contient les éventuelles erreurs survenues.



Lorsque vous lancez make test, la page HTML générée pour chaque fichier de tests contiendra une représentation graphique du programme CFG.

L'optimisation à laquelle on s'intéresse est l'élimination des affectations mortes. Cette optimisation permet de supprimer du programme les affectations  $\mathbf{v}:=\mathbf{e}$  telles que la valeur de  $\mathbf{v}$  n'est jamais lue après cette affectation. Il est aisé de comprendre que dans ce cas, cette affectation peut être supprimée sans modifier le comportement du programme.  $^2$ 

Pour déterminer quelles affectations peuvent être éliminées, nous allons procéder à une analyse de vivacité des variables.

## 7.1 Analyse de vivacité

Cette partie se passe dans le fichier cfg\_liveness.ml. Le but de cette analyse est d'obtenir, pour chaque nœud du programme, l'ensemble des variables qui sont *vivantes* avant et après ce nœud. Il nous suffit en fait de calculer l'ensemble des variables vivantes avant chaque nœud; on pourra calculer, au besoin, à partir de cela les variables vivantes après chaque nœud.

Pour stocker l'ensemble des variables vivantes avant chaque nœud, on utilisera une table de hâchage indexée par des entiers (les identifiants des nœuds du CFG) : (int, string Set.t) Hashtbl.t.

L'analyse se déroulera en calculant le point fixe des équations de flot de données vues en cours, jusqu'à ce qu'une solution stable soit trouvée (*i.e.* jusqu'à ce qu'on n'ajoute plus de variable vivante à aucun point de programme).

Chaque itération de l'analyse mettra à jour l'état de l'analyse, *i.e.* le mapping entre les identifiant de nœuds et la liste des variables vivantes avant ce nœud. Pour chaque nœud, on commencera par calculer l'ensemble des variables vivantes après ce nœud : il s'agit de l'union des variables vivantes avant chacun de ces successeurs. À partir de cet ensemble, on calculera l'ensemble des variables vivantes avant ce nœud : les variables lues deviennent vivantes et les variables écrites deviennent mortes.

Question 7.1. Écrivez une fonction vars\_in\_expr : expr -> string Set.t qui renvoie l'ensemble des variables utilisées par une expression.

Nous vous fournissons, dans le fichier cfg.ml, les fonctions succs : (int, cfg\_node)

Hashtbl.t -> int -> int Set.t et preds : (int, cfg\_node) Hashtbl.t -> int -> int

Set.t qui renvoient respectivement les successeurs et prédécesseurs d'un nœud dans un CFG.

Question 7.2. Écrivez une fonction live\_after\_node : (int, cfg\_node) Hashtbl.t -> int -> (int, string Set.t) Hashtbl.t -> string Set.t. Plus précisément, life\_after\_node cfg n lives calcule l'ensemble des variables vivantes après exécution du nœud n dans le graphe cfg, étant donné l'ensemble des variables vivantes avant chaque nœud donné par la table lives.

Autrement dit, il s'agit d'une itération du calcul de in dans les équations de flot de données.

<sup>2.</sup> Attention, dans des langages plus riches que le langage E, comme C par exemple, cela n'est valable que si l'expression e n'a pas d'effets de bord.



Question 7.3. Écrivez une fonction live\_cfg\_node : cfg\_node -> string Set.t -> string Set.t. Par exemple, live\_cfg\_node node live\_after doit renvoyer l'ensemble des variables vivantes avant le nœud n, où liv\_after est l'ensemble des variables vivantes après ce nœud.

Autrement dit, il s'agit d'une itération du calcul de out dans les équations de flot de données.

Question 7.4. Utilisez les fonctions précédentes pour écrire une fonction live\_cfg\_nodes (cfg: (int, cfg\_node) Hashtbl.t) (lives : (int, string Set.t) Hashtbl.t) : bool qui effectue une itération du calcul de point fixe sur le CFG cfg en partant de l'état lives.

Cette fonction met à jour la table lives et renvoie un booléen qui indique si des changements ont eu lieu sur au moins un nœud.

Question 7.5. Écrivez finalement la fonction live\_cfg\_fun : cfg\_fun -> (int, string Set.t) Hashtbl.t. Cette fonction calcule l'ensemble des variables vivantes avant chaque nœud du CFG correspondant à une fonction donnée.

## 7.2 Élimination de code mort

Cette partie se passe dans le fichier cfg\_dead\_assign.ml. Nous allons maintenant utiliser le résultat de notre analyse pour optimiser notre programme. Nous allons parcourir le graphe de flot de contrôle et pour chaque nœud correspondant à une affectation (Cassign), si la variable affectée n'est pas vivante après l'affectation, nous allons supprimer cette affectation (plus précisément transformer le nœud en un nouveau nœud de type Cnop).

Question 7.6. Écrire une fonction dead\_assign\_elimination\_fun (f: cfg\_fun) : cfg\_fun qui, étant donnée une fonction de CFG, calcule la vivacité des variables et élimine les affectations mortes.

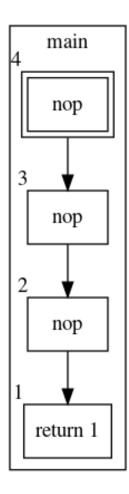
Dans certains cas, le programme transformé peut encore être simplifié par l'application de cette même transformation. En effet, certaines variables pouvaient être vivantes seulement parce qu'elles étaient utilisées dans une affectation concernant une variable elle-même morte. C'est le cas par exemple de l'exemple useless\_assigns.e présent dans votre répertoire tests.

Question 7.7. Modifiez votre code pour appliquer la transformation autant que nécessaire.

## 7.3 Bonus : élimination de NOPs

Dans la section précédente, on a transformé certains nœuds en Cnop, c'est-à-dire no op ou no operation. On s'intéresse maintenant à éliminer ces NOPs.





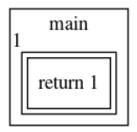
Par exemple, le CFG pour le programme tests/basic/useless-assigns.e ressemblera au CFG ci-contre.

Un certain nombre de fonctions à compléter sont présentes dans le fichier src/cfg\_nop\_elim.ml.

Sur l'exemple ci-contre :

```
- nop_transitions cfg = [(4,3); (3,2); (2,1)]
- follow 4 _ _ = 1
- follow 3 _ _ = 1
- follow 2 _ _ = 1
- follow 1 _ _ = 1
- nop_transitions_closed cfg = [(4,1); (3,1); (2,1); (1;1)]
```

Après application de l'optimisation, le CFG devrait ressembler à :





# 8 TP5 : Génération de programmes RTL

L'objectif de cette séance de TP est de générer des programmes RTL (Register Transfer Language). Comme expliqué dans la section 2, RTL est un language dans lequel le programme est un graphe de flot de contrôle, comme en CFG, mais où les expressions, contrairement à CFG, sont décomposées en opérations élémentaires sur des registres. Il n'y a pas de limites au nombre de registres qu'un programme RTL utilise. En RTL, on perd la notion de variable : toutes les données sont dans des (pseudo-)registres.

Pourquoi choisit-on un tel langage intermédiaire? Ce langage intermédiaire permet de se rapprocher de l'assembleur qui sera généré in fine, on dit qu'il est plus bas niveau que les langages précédents. C'est un choix courant dans des compilateurs connus : le compilateur GCC utilise un langage qui s'appelle aussi RTL et qui partage un certain nombre de caractéristiques avec notre langage RTL, la représentation intermédiare IR de Clang y ressemble aussi, et CompCert utilise également un langage RTL.

La description du langage RTL se trouve dans le fichier src/rtl.ml. On y trouve notamment le type des registres reg (qui est un synonyme pour int).

Les instructions RTL (type rtl\_instr) sont :

- Opération binaire RBinop(b, rd, rs1, rs2) : on effectue l'opération binaire b sur les registres source rs1 et rs2, et on stocke le résultat dans le registre destination rd.
- Opération unaire RUnop(u, rd, rs): on effectue l'opération unaire u sur le registre source rs, et on stocke le résultat dans le registre destination rd.
- Opération Rconst(r, i) : on stocke la constante i dans le registre r.
- Opération Rmov(rd, rs) : on copie la valeur contenue dans le registre source rs dans le registre destination rd.
- Opération « label » **Rlabel 1** : on définit un *label* à cet endroit du code. On pourra y sauter par la suite, mais cette opération ne fait rien.
  - **Note :** on ne se servira des labels qu'à partir du langage Linear. Pour le moment, on ne produit pas de labels dans le code RTL, et les cibles des instructions de saut **Rbranch** et **Rjmp** sont des identifiants des nœuds dans le CFG.
- Opération de branchement Rbranch(cmp, rs1, rs2, 1): on évalue la comparaison cmp (de type rtl\_cmp défini plus haut) sur les registres rs1 et rs2. Si la comparaison s'évalue en vrai (pas zéro), on saute au label 1; sinon on continue l'évaluation normalement.
- Opération de saut inconditionnel Rjmp 1 : on saute au label 1.
- Opération **Rprint** r : affichage du contenu du registre r.
- Opération **Rret** r : on retourne la valeur contenue dans le registre r, et on arrête l'exécution de la fonction courante.

## 8.1 Génération de programmes RTL

Voici le plan d'attaque pour la transformation de programmes CFG en programmes RTL.

- 1. Tout d'abord, il nous faut un moyen de générer des nouveaux noms de registres. Les fonctions que nous allons écrire prendront donc en paramètre un couple (next\_reg, var2reg), où :
  - next\_reg est le numéro du prochain registre disponible (pas encore alloué à une variable, ou utilisé comme registre intermédiaire);



- var2reg : (string \* int) list est une liste d'association qui contient une paire (v,
   r) si le registre RTL r est associé à la variable CFG dont le nom est v.
- 2. Équipés de ces paramètres, il nous faudra transformer les expressions et instructions CFG en opérations RTL.

Le travail à effectuer se trouve dans le fichier src/rtl\_gen.ml.

La fonction find\_var (next\_reg, var2reg) v, écrite pour vous, renvoie un triplet (r, next\_reg', var2reg') où r correspond au registre correspondant à la variable v, et next\_reg' et var2reg' sont les paramètres d'entrée mis à jour.

Passons maintenant à la compilation des expressions. La compilation d'une expression CFG va produire une liste d'opérations RTL qui vont avoir pour effet de calculer l'expression en question et de stocker sa valeur dans un registre. La fonction rtl\_instrs\_of\_cfg\_expr (next\_reg, var2reg) e effectue cette transformation et doit renvoyer un quadruplet (r, l, next\_reg', var2reg') tel que :

- le résultat de l'expression CFG e est stocké dans le registre r;
- la liste d'instructions RTL correspondant au calcul de ce résultat est 1;
- next\_reg' est var2reg' sont les variables next\_reg et var2reg passées en paramètre, éventuellement mises à jour.

Par exemple, pour compiler l'expression a + 2 \* b, en supposant que next\_reg vaut 0 et var2reg est initialement vide :

— on commence par compiler la sous-expression a. On va donc appeler la fonction find\_var qui nous renverra un triplet (0, 1, [("a", 0)]).

Le résultat de la compilation de cette première sous-expression donnera le quadruplet (0, [], 1, [("a", 0)]). (Aucune opération n'est requise.)

— on compile ensuite la sous-expression 2 \* b.

Tout d'abord, la compilation de la sous-expression 2 nous renverra le quadruplet :

```
(1, [Rconst(1, 2)], 2, [("a", 0)]).
```

Puis, la compilation de la sous-expression b nous renverra le quadruplet :

```
(2, [], 3, [("a", 0); ("b", 2)]).
```

Finalement, on obtiendra pour la sous-expression 2 \* b:

```
(3, [Rconst(1,2); Rbinop(Emul, 3, 1, 2)], 4, [("a", 0); ("b", 2)]).
```

— On combine ces deux sous-résultats : il nous faut un nouveau registre pour stocker le résultat de l'expression en entier :

```
(4, [Rconst(1,2); Rbinop(Emul, 3, 1, 2); Rbinop(Eadd, 4, 1, 3)], 5, [("a", 0); ("b", 2)])
```

```
Question 8.1. Écrivez la fonction rtl_instrs_of_cfg_expr (next_reg, var2reg) e.
```

Les expressions sont maintenant compilées, passons aux nœuds du CFG. Ceux-ci sont transformés en des nœuds RTL, qui partageront le même identifiant. Seulement, au lieu de contenir une « instruction » CFG, ils contiendront une liste d'opérations RTL.



Question 8.2. Écrivez la fonction rtl\_instrs\_of\_cfg\_node (next\_reg, var2reg) (c: cfg\_node) qui renvoie, étant donné un nœud CFG, un triplet (1, next\_reg', var2reg') où 1 est la liste des opérations RTL correspondant à un nœud CFG c et next\_reg' et var2reg' ont le même sens que précédemment.

Vous noterez la présence de la fonction rtl\_cmp\_of\_cfg\_expr : nous vous laissons interpréter ce qu'elle fait et comment l'utiliser... Sans doute pour les opérations de branchement?

La fonction suivante, rtl\_instrs\_of\_cfg\_fun, est écrite entièrement pour vous et ne fait qu'utiliser les fonctions précédentes pour construire une fonction RTL. Jetez-y un œil pour comprendre ce qui s'y passe.

Vous avez désormais des programmes RTL!

Un afficheur et un interpréteur de RTL vous sont fournis, à utiliser comme ci-dessous :

```
$ ./main.native -f tests/basic/gcd.e -rtl-dump -
main(r0, r1):
main_2:
r2 <- 0
r1 != r2 ? jmp main_5
jmp main_1
main_3:
r0 <- r3
jmp main_2
main 5:
r3 <- r1
jmp main_4
main_4:
r4 <- %(r0, r1)
r1 <- r4
jmp main_3
main_1:
ret r0
$ ./main.native -f tests/basic/gcd.e -rtl-run -- 21 14
  { "compstep": "Lexing", "error": null, "data": [] },
  { "compstep": "Parsing", "error": null, "data": [] },
  { "runstep": "RTL", "retval": 7, "output": "", "error": null },
```

# 8.2 Linéarisation des programmes RTL

Les programmes RTL sont des graphes de flot de contrôle. La phase suivante est la linéarisation des programmes, c'est-à-dire transformer le graphe en un programme du langage Linear (définis dans le fichier src/linear.ml), qui ne sont qu'une liste d'instructions RTL, incluant des sauts explicites.

Une linéarisation naïve est implémentée dans le fichier src/linear\_gen.ml. Cette linéarisation est naïve car les différents blocs d'instructions RTL sont mis les uns à la suite des autres sans considération du graphe de flot de contrôle, et donc sans doute que trop de sauts sont utilisés.

Vous avez donc une linéarisation qui fonctionne, mais qui pourrait être améliorée. Voici comment :



- on pourrait ordonner les nœuds du graphe de flot de contrôle original selon un ordre topologique, c'est-à-dire un parcours en profondeur du graphe.
- si deux blocs d'instructions sont ordonnées l'un juste après l'autre, on peut éviter un saut. Autrement dit, on n'a pas besoin de la suite d'instructions [Rjmp 1; Rlabel 1] (sauter à l'instruction suivante).
- après la transformation précédente, on peut éliminer les labels auxquels aucune instruction ne saute.

Cette section étant optionelle, peu de détails sont fournis et il vous appartient d'explorer comment mettre en place les différentes optimisations présentées ci-dessus.



# 9 TP6: Allocation de registres

Le but de cette séance de travaux pratiques est de réaliser l'allocation de registre, qui permettra de produire du code assembleur qui pourra être assemblé et exécuté par un processeur RISC-V.

L'allocation de registres consiste à spécifier, pour chaque pseudo-registre RTL (ou Linear), à quel emplacement matériel on va le stocker. Concrètement, on associe à chaque pseudo-registre RTL soit un registre matériel, soit un emplacement sur la pile.

Nous vous fournissons un « allocateur de registre » très simple qui alloue tous les pseudo-registres RTL sur la pile et n'utilise donc aucun registre matériel. C'est assurément inefficace puisque cela va générer un grand nombre de lectures/écritures dans la mémoire, mais ça a le mérite de fonctionner.

Vous avez donc déjà un compilateur qui génère des programmes RISC-V exécutables!

```
$ ./main.native -f tests/basic/gcd.e
  { "compstep": "Lexing", "error": null, "data": [] },
  { "compstep": "Parsing", "error": null, "data": [] },
  { "compstep": "CFG", "error": null, "data": [ { "main": 14 } ] },
  { "compstep": "CFG loops", "error": null, "data": [ { "main": 15 } ] },
  { "compstep": "Constprop", "error": null, "data": [ { "main": 15 } ] },
  { "compstep": "DeadAssign", "error": null, "data": [ { "main": 15 } ] },
  { "compstep": "NopElim", "error": null, "data": [ { "main": 14 } ] },
  { "compstep": "DSE", "error": null, "data": [] }
$ tests/basic/gcd.exe 54 24
$ $ ./main.native -f tests/basic/prime.e
 { "compstep": "Lexing", "error": null, "data": [] },
  { "compstep": "Parsing", "error": null, "data": [] },
 { "compstep": "CFG", "error": null, "data": [ { "main": 46 } ] },
 { "compstep": "CFG loops", "error": null, "data": [ { "main": 48 } ] },
 { "compstep": "Constprop", "error": null, "data": [ { "main": 48 } ] },
 { "compstep": "DeadAssign", "error": null, "data": [ { "main": 48 } ] },
   "compstep": "NopElim", "error": null, "data": [ { "main": 46 } ] },
  { "compstep": "DSE", "error": null, "data": [] }
$ tests/basic/prime.exe 54
54
2
3
3
3
0
```

On sait calculer le PGCD de deux entiers et décomposer un entier en facteurs premiers!

De plus, le fichier HTML généré pour chacun des fichiers source (par exemple tests/basic/gcd.e.html) contient, dans la section LTL, l'allocation de chaque pseudo-registre RTL. Par exemple, pour le test tests/basic/gcd.e, on a l'allocation suivante :

```
// In function main
// LinReg 1 allocated to a1
// LinReg 0 allocated to a0
```



```
// LinReg 4 allocated to stk(-32)
// LinReg 3 allocated to stk(-24)
// LinReg 2 allocated to stk(-16)
```

Vous remarquerez que certains pseudo-registres (1 et 0) sont alloués dans des vrais registres machine  $(\mathtt{a1} \text{ et } \mathtt{a0})$  tandis que les autres (2, 3 et 4) sont alloués sur la pile, aux emplacements -16, -24 et -32.

L'objectif de la suite de cette séance est donc d'écrire un allocateur de registres plus intelligent, qui utilisera mieux les registres disponibles en RISC-V.

## 9.1 Crash course: assembleur RISC-V

RISC-V est une architecture de jeu d'instruction (ISA) ouverte et libre. C'est une architecture de type RISC (Reduced Instruction Set Computer) avec relativement peu d'instructions et un plus grand nombre de registres (comparé à x86 par exemple qui est de type CISC (Complex Instruction Set Computer) et qui a énormément d'instructions et peu de registres). Nous allons présenter ici un sous-ensemble des instructions RISC-V – celles dont on a besoin pour écrire notre compilateur. À noter que nous vous fournissons le code pour la génération de l'assembleur RISC-V (dans src/riscv.ml). Les descriptions qui suivent vous serviront donc pour votre culture, ainsi que pour comprendre le code qui vous est fourni lorsque vous devrez l'étendre.

## 9.1.1 Registres RISC-V

RISC-V existe en 32 bits ou 64 bits (et même 128 bits). Nous allons écrire du code pour RISC-V 32 et 64. Rassurez-vous, la plupart du code peut se factoriser aisément. Dans cette architecture, RISC-V donne accès à 32 registres de 32 ou 64 bits chacun (selon l'architecture), dont voici la liste :

Numéro	Nom	Commentaire	Numéro	Nom	Commentaire
x0	zero	vaut toujours zéro	x16	a6	arguments
x1	ra	adresse de retour	x17	a7	arguments
x2	$^{\mathrm{sp}}$	pointeur de pile	x18	s2	
x3	gp	$global\ pointer$	x19	s3	
x4	tp	thread pointer	x20	s4	
x5	t0		x21	s5	
x6	t1	temporaires	x22	s6	registres callee-save
x7	t2		x23	s7	registres carree-save
x8	s0/fp	frame pointer	x24	s8	
x9	s1	registre callee-save	x25	s9	
x10	a0	argument / valeur de retour	x26	s10	
x11	a1		x27	s11	
x12	a2		x28	t3	
x13	a3	arguments	x29	t4	temporaires
x14	a4		x30	t5	temporanes
x15	a5		x31	t6	

Le registre zero contient toujours la valeur 0.

Le registre ra est utilisé pour stocker l'adresse de retour lors d'un appel de fonction. <sup>3</sup>

<sup>3.</sup> Notons que ce n'est qu'une convention et que l'on pourrait stocker l'adresse de retour dans n'importe quel registre.



Le registre sp contient le pointeur de pile (similaire à esp en x86).

Le registre gp est le *global pointer*. Il contient l'adresse de la zone de mémoire où sont stockées les variables globales. Nous ne l'utiliserons pas dans notre compilateur.

Le registre tp est le *thread pointer*. Il contient l'adresse de la zone de mémoire propre au thread courant. Nous ne l'utiliserons pas dans notre compilateur.

Les registres t0 à t6 sont des registres temporaires qui n'ont pas de vocation particulière.

Le registre s0, aussi appelé fp pour *frame pointer*, contient l'adresse du début de la trame de pile de la fonction courante. C'est l'analogue du registre ebp en x86.

Les registres \$1 à \$11 sont des registres temporaires sans vocation particulière.

Les registres a0 à a7 sont utilisés pour passer les arguments lors d'un appel de fonction (premier argument dans a0, second dans a1...). De plus, la valeur de retour des fonctions est passée dans le registre a0.

Registres caller- et callee-save. Les registres ra, t0-t6 et a0-a7 sont *caller-save*, c'est-à-dire que c'est la responsabilité de la fonction appelante (le *caller*) de sauvegarder ces registres avant de faire un appel de fonction si leur valeur est importante.

Les registres sp, s0-s11 sont *callee-save*, c'est-à-dire que c'est la responsabilité de la fonction appelée (le *callee*) de sauvegarder ces registres si la fonction appelée les modifie. On peut donc faire l'hypothèse, lorsqu'on appelle une fonction, que la valeur de ces registres sera la même après l'appel.

## 9.1.2 Instructions.

Contrairement à x86, où les instructions acceptent plusieurs modes d'adressage pour les opérandes (registres, valeurs immédiates, emplacements mémoire), les instructions RISC-V ont en général un unique mode d'adressage.

La plupart des instructions sont de type « 3 adresses » et attendent des registres comme opérandes. Deux schémas principaux émergent :

- op rd, rs1, rs2 où op est une opération (add, mul, div, remu (pour remainder unsigned, a.k.a. modulo)...), rd est le registre de destination, et rs1 et rs2 sont les registres source.
- op rd, rs où op est une opération (neg, ...), rd est le registre de destination, et rs est le registre source.

Pour compiler les conditionnelles (par exemple  $r1 \leftarrow r2 \leftarrow r3$ ), on a besoin des instructions supplémentaires suivantes :

```
— slt rd, rs1, rs2: rd vaut 1 \text{ si rs1} < \text{rs2}, 0 \text{ sinon}
```

- segz rd, rs : rd vaut 1 si rs vaut zéro, 0 sinon
- snez rd, rs:rd vaut 0 si rs vaut zéro, 1 sinon

## Les instructions de branchement.

```
— Saut inconditionnel : j <label>
```

- Appel de fonction : jal ra, <label>
- Saut si deux registres sont égaux : beq rs1, rs2, <label>
- Saut si rs1 < rs2 (en unsigned ou pas): blt[u] rs1, rs2, <label>
- Saut si rs1 >= rs2 (en unsigned ou pas) : bge[u] rs1, rs2, <label>
- Saut si rs != 0 : bnez rs, <label>



#### Accès à la mémoire

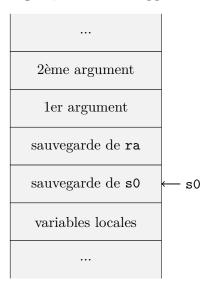
- Lire depuis la mémoire vers un registre : ld rd, ofs(rs). Cette instruction lit la mémoire à l'adresse rs + ofs et stocke le résultat dans le registre rd.
  - 1d veut dire *load double-word*, i.e. 64 bits. Pour ne lire que 32 bits, on aurait utilisé 1w pour *load word*; pour 16 bits 1h pour *load half-word* et pour 8 bits 1b pour *load byte*.
- Écrire la valeur d'un registre dans la mémoire : sd rs, ofs(rd). Cette instruction écrit la valeur du registre rs dans la mémoire à l'adresse rd + ofs.
  - sd veut dire *store double-word*, i.e. 64 bits. Pour n'écrire que 32 bits, on aurait utilisé sw pour *store word*; pour 16 bits sh pour *store half-word* et pour 8 bits sb pour *store byte*.

Valeurs immédiates Pour écrire une constante dans un registre : li rd, imm, où rd est le registre de destination et imm est la constante que l'on souhaite stocker.

#### 9.1.3 Code fourni

Nous vous fournissons un allocateur de registres « naïf », dans le fichier src/regalloc.ml. Plus précisément, l'allocateur de registres regalloc\_on\_stack\_fun prend en entrée une fonction linear\_fun et renvoie un couple ((reg, loc) Hashtbl.t \* int). Le premier élément du couple est une table de hachage qui associe à chaque pseudo-registre un emplacement (location en anglais) de type loc définie comme suit :

Un emplacement est donc soit un registre physique du processeur cible (ici le processeur RISC-V), soit un slot sur la pile. Un tel slot est un décalage par rapport au registre fp (frame pointer ou cadre de pile). Notez que puisque sur RISC-V (comme sur x86 d'ailleurs) le sommet de pile (le registre sp) décroît vers des adresses plus petites lorsque l'on empile des données sur celle-ci, le décalage entre une variable locale évincée sur la pile et le registre de cadre de pile fp est toujours un entier négatif, comme cela apparaît sur la figure :



L'allocateur fourni fonctionne de manière très simple en parcourant l'ensemble des instructions d'une fonction en langage Linear afin de déterminer les pseudo-registres qu'elle utilise. Pour cela, on fait appel aux fonctions gen\_live et kill\_live qui vous sont fournies dans le fichier



src/linear\_liveness.ml dont le but est précisément de calculer la vivacité des pseudo-registres en langage Linear. On ne vous demande pas de coder de nouveau cette analyse de vivacité puisqu'elle a déjà fait l'objet d'un TP. En faisant l'union de tous les pseudo-registres utilisés par une fonction, il reste plus qu'à itérer sur la liste de ces registres pour allouer à chacun un slot (un entier négatif) qui décroît de 1 pour chacun d'eux (puisque pour le moment toutes les variables sont de type entier de longueur égale à celle de l'architecture sous-jacente).

## 9.2 Allocation de registres

Bien qu'on ait à présent un compilateur complet (dans le sens où on génère des fichiers exécutables), on peut apporter un grand nombre d'améliorations à notre compilateur. Dans cette partie, nous allons écrire un allocateur de registres afin de profiter de la multitude de registres disponibles en RISC-V; et minimiser le nombre d'instructions qui accèdent à la mémoire.

Nous allons écrire un algorithme basé sur la coloration de graphes, comme vu en cours. Pour cela il est nécessaire de procéder au préalable à une analyse de vivacité des pseudo-registres utilisés dans le langage Linear. Comme expliqué plus tôt, cette analyse vous est fournie (fichier src/linear liveness.ml.

Lorsque vous lancez un test sur un exemple, vous pouvez consulter le résultat de cette phase d'analyse de vivacité dans le fichier .linear associé au code compilé :

```
$ ./test.py -f basic/gcd.e
1 threads running (['basic/gcd.e']).
All threads terminated!
1/1 OK.
0/1 KO : []
$ cat basic/gcd.linear
main(r0, r1):
// Live before : { 0, 1 }
main 2:
// Live after : { 0, 1 }
// Live before : { 0, 1 }
// Live after : { 0, 1, 2 }
// Live before : { 0, 1, 2 }
r1 != r2 ? jmp main_5
// Live after : { 0, 1 }
// Live before : { 0 }
jmp main_1
// Live after : { 0 }
// Live before : { 0, 1 }
main 5:
// Live after : { 0, 1 }
// Live before : { 0, 1 }
r3 <- r1
// Live after : { 0, 1, 3 }
// Live before : { 0, 1, 3 }
r4 <- %(r0, r1)
// Live after : { 3, 4 }
// Live before : { 3, 4 }
r1 <- r4
// Live after : { 1, 3 }
// Live before : { 1, 3 }
r0 <- r3
// Live after : { 0, 1 }
```



```
// Live before : { 0, 1 }
jmp main_2
// Live after : { 0, 1 }
// Live before : { 0 }
main_1:
// Live after : { 0 }
// Live before : { 0 }
ret r0
// Live after : { }
```

À partir de cette analyse, nous allons construire un graphe d'interférences : les sommets sont les différents pseudo-registres utilisés dans le programme et on a une arête entre deux pseudo-registres si ceux-ci sont vivants en même temps. Intuitivement, deux pseudo-registres vivants en même temps ne pourront pas être associés au même registre machine. Le problème d'allocation de registre devient alors un problème de coloration de graphes : on souhaite associer une couleur à chaque sommet de sorte que deux sommets voisins dans le graphe sont associés à des couleurs différentes.

## 9.2.1 Allocation de registres par coloration de graphes

Passons maintenant à la construction du graphe d'interférence et à sa coloration. Cela se passe dans le fichier src/regalloc.c.

Construction du graphe d'interférence. La construction du graphe d'interférence sera effectuée par la fonction build\_interference\_graph (live\_out : (int, reg Set.t) Hashtbl.t) : (reg, reg Set.t) Hashtbl.t qui renvoie le graphe d'interférence à partir d'une analyse de vivacité. L'analyse de vivacité est passée sous la forme d'une table de hachage qui associe à chaque instruction du code en langage Linear (identifiée par un entier : sa position dans le programme) un ensemble de registres vivants à la sortie de cette instruction. Cette fonction retourne un graphe d'interférence sous la forme d'une table de hachage qui associe un arc (dirigé) entre chaque registre et les registres avec lequel ce registre est en interférence et donc adjacent dans le graphe.

C'est à vous de construire le graphe, à partir du résultat de vivacité. Vous devez ajouter des arêtes entre deux sommets si à au moins un point de programme, les pseudo-registres associés à ces deux sommets sont vivants en même temps.

```
Question 9.1. Écrivez une fonction add_interf (rig : (reg, reg Set.t) Hashtbl.t) (x: reg) (y: reg) : unit qui met à jour le graphe d'interférence rig (pour register interference graph) en ajoutant un lien entre les sommets x et y.
```

Attention, étant donnée la représentation que l'on a choisi pour le graphe (sous forme de listes d'adjacence), ajouter une arête implique d'ajouter  ${\tt x}$  aux voisins de  ${\tt y}$  et  ${\tt y}$  aux voisins de  ${\tt x}$ .

```
Question 9.2. Écrivez une fonction make_interf_live (rig: (reg, reg Set.t) Hashtbl.t) (live: (int, reg Set.t) Hashtbl.t): unit qui construit le graphe d'interférence.
```

On vous fournit la fonction build\_interference\_graph (live\_out : (int, reg Set.t) Hashtbl.t) : (reg, reg Set.t) Hashtbl.t qui s'assure d'initialiser correctement le graphe



d'interférences avec autant de sommets qu'il y a de pseudo-registres utilisé dans le programme Linear. Cette fonction utilise les fonctions que vous avez définies précédemment.

Coloration du graphe L'algorithme d'allocation de registres par coloration de graphes a été initialement proposé dans un article de recherche par Chaitin et al. en 1981 <sup>4</sup>.

On suppose que l'on dispose de N couleurs (registres machine). L'algorithme se déroule en plusieurs phases :

1. On commence par construire une pile de pseudo-registres en indiquant pour chacun si on va être capable d'y associer une couleur (un registre machine) à coup sûr, ou non (dans ce cas, il devra être alloué sur la pile – on dit qu'il est évincé ou *spilled*).

La construction de cette pile s'effectue comme suit :

Tant que le graphe rig n'est pas vide :

- on essaie de trouver un sommet avec strictement moins de N voisins dans rig
  - Si un tel sommet r existe, retirons-le du graphe rig et ajoutons ce registre au sommet de la pile en indiquant qu'on saura lui associer une couleur. Dans notre code on met sur la pile NoSpill r.
  - Sinon, on va devoir évincer (spiller) un pseudo-registre, c'est-à-dire choisir un pseudo-registre qui sera alloué sur la pile. On peut choisir n'importe quel sommet, mais une heuristique particulière consiste à choisir le sommet qui a le plus de voisins : cela aura pour effet de diminuer le nombre de voisins de beaucoup d'autres registres et de permettre de trouver plus facilement par la suite un sommet avec moins de N voisins. On retire ce sommet du graphe, et on l'ajoute au sommet de la pile en indiquant qu'il sera évincé. Dans notre code on met sur la pile Spill r.
- 2. Une fois cette pile construite, on va effectivement associer des couleurs à chaque sommet marqué NoSpill et des emplacements sur la pile à chaque sommet marqué Spill.

Question 9.3. Écrivez une fonction remove\_from\_rig (rig : (reg, reg Set.t) Hashtbl.t) (v: reg) : unit qui supprime un sommet v du graphe d'interférence rig passé en paramètre.

Attention, étant donnée la représentation que l'on a choisi pour le graphe (sous forme de listes d'adjacence), supprimer un sommet nécessite de parcourir tous les éléments de la table de hachage pour retirer toute référence à ce sommet.

Question 9.4. Écrivez une fonction pick\_node\_with\_fewer\_than\_n\_neighbors (rig: (reg, reg Set.t) Hashtbl.t) (n: int): reg option qui renvoie Some(r), avec r un registre de rig possédant moins de n voisins quand c'est possible, et None sinon.

Question 9.5. Écrivez une fonction pick\_spilling\_candidate (rig : (reg, reg Set.t) Hashtbl.t) : reg option qui renvoie un sommet que l'on va évincer. Choisissez le sommet avec le maximum de voisins. Comme pour la fonction précédente, renvoyez Some(r) lorsque le

<sup>4.</sup> Chaitin, Gregory J.; Auslander, Marc A.; Chandra, Ashok K.; Cocke, John; Hopkins, Martin E.; Markstein, Peter W. (1981). "Register allocation via coloring".



graphe n'est pas vide ou **None** dans le cas contraire.

On vous fournit le type regalloc\_decision = Spill of reg | NoSpill of reg

Question 9.6. Écrivez la fonction récursive make\_stack (rig : (reg, reg Set.t) Hashtbl.t) (stack : regalloc\_decision list) (ncolors: int) : regalloc\_decision list qui à partir d'un graphe d'interférence, d'une pile de décision (déjà partiellement construite et éventuellement vide), d'un nombre de registres disponibles étend la pile passée en paramètre comme décrit plus haut.

Les fonctions make\_stack et allocate sont appelées par la fonction

qui vous est donnée déjà complétée. Cette fonction déroule l'allocation de registres pour une fonction d'un programme Linear. Elle renvoie un triplet contenant :

- 1. le graphe d'interférence qui peut être visualisé à partir de sa représentation en fichier .dot.
- 2. une table de hachage décrivant une association entre chaque pseudo-registre du programme en Linear et un emplacement;
- 3. la prochaine position libre sur la pile.

Cette fonction est elle-même appelée par la fonction regalloc lp lives all\_colors qui fait ce même travail mais sur un programme Linear complet (éventuellement composé de plusieurs fonctions).

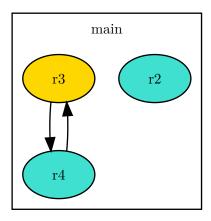


```
$ ./main.native -f tests/basic/gcd.e -clever-regalloc -ltl-dump -
// In function main
// LinReg 1 allocated to a1
// LinReg 4 allocated to t2
// LinReg 3 allocated to s1
// LinReg 0 allocated to a0
// LinReg 2 allocated to t2
[...]
```

Dans la commande précédente, on a passé un certain nombre d'options :

- -clever-regalloc pour utiliser l'allocateur de registres que l'on vient de programmer.
- <u>-ltl-dump</u> pour afficher le programme LTL (pour comprendre à quoi correspondent les pseudo-registres)

Le graphe d'interférence est visible dans le fichier DOT tests/basic/gcd.rig et déjà converti en SVG pour vous dans tests/basic/gcd.rig.svg:



On y voit que les registres r2 et r4 sont alloués dans le même registre physique (t2, d'après le dump LTL précédent).

Les registres r3 et r4 sont dans des registres différents, parce qu'ils sont en interférence. Effectivement, on avait vu dans le dump Linear, quelques pages plus haut, que ces registres étaient vivants ensemble à un point de programme.

On ne voit pas les registres r0 et r1 dans ce graphe, qui correspondent aux arguments de la fonction. Effectivement, les arguments sont alloués dans des registres séparés (a0 à a7, puis sur la pile si nécessaire, mais à des offsets positifs par rapport à fp, depuis la fonction appelée), leur allocation sera faite automatiquement pour vous dans src/ltl\_gen.ml.

## 9.3 Tester

Pour lancer les tests, vous avez utilisé depuis le début de ces séances de TP la commande make test. Mais vous ne connaissez pas toute la puissance qui se cache derrière cette commande!

Par défaut, make test lance le script Python tests/test.py sur l'ensemble des fichiers \*.e qui se trouvent dans le répertoire tests/basic. Aussi, par défaut, l'allocateur de registres « naïf » est utilisé.

Vous pouvez modifier ce comportement par défaut en passant des paramètres à votre commande make .



Pour passer des paramètres supplémentaires au compilateur (*i.e.* au ./main.native), on passe ces paramètres dans la variable OPTS de la manière suivante :

Pour lancer les tests sur un ensemble de fichiers source, on passe ces paramètres dans la variable de la manière suivante :

```
$ make test DIR="basic/prime.e basic/gcd.e"
# ...
./test.py -f basic/prime.e basic/gcd.e
2 threads running (['basic/prime.e', 'basic/gcd.e']).
All threads terminated!
2/2 OK.
0/2 KO : []
```

Vous pouvez évidemment combiner ces deux options :

```
$ make test OPTS=-clever-regalloc DIR="basic/prime.e basic/gcd.e"
# ...
./test.py -f basic/prime.e basic/gcd.e -clever-regalloc
# ...
```



# 10 Appels de fonctions

Le langage de votre compilateur est pour l'instant quelque peu limité. Notamment, on ne sait pas faire d'appels de fonctions. C'est la prochaine étape pour améliorer votre compilateur. Vous pourrez alors compiler des programmes qui ressemblent à celui-ci :

```
fib(n){
   if(n > 14){    return -1; }
   if(n <= 2){
      return 1;
   } else {
      return fib(n-1) + fib(n-2);
   }
}
main(n){
   return fib(n);
}</pre>
```

Comme vous le constatez, il s'agit d'une implémentation de la suite de Fibonacci de manière récursive et inefficace (on calcule plusieurs fois les mêmes valeurs...). Pour que les calculs ne durent pas trop longtemps, on abandonne et on renvoie -1 pour une entrée supérieure à 14.

Notons que pour le moment, nous n'avons toujours pas de type : toutes les variables sont entières. Le programme ci-dessus ainsi que 10 autres vous sont fournis dans le répertoire funcall.

Pour étendre votre compilateur, il va vous falloir modifier votre grammaire, ainsi que chacun des langages intermédiaires et des différentes passes de compilation. Voici un aperçu des changements à effectuer :

## 10.1 La grammaire

Une instruction peut maintenant être un appel de fonction (en plus des cas existants d'affectation, de boucles, ...) :

```
x = 3;
y = 8;
f(x,y); // Un appel de fonction, en tant qu'instruction.
z = x + y;
```

Une **expression** peut aussi contenir des appels de fonctions :

```
x = 3;

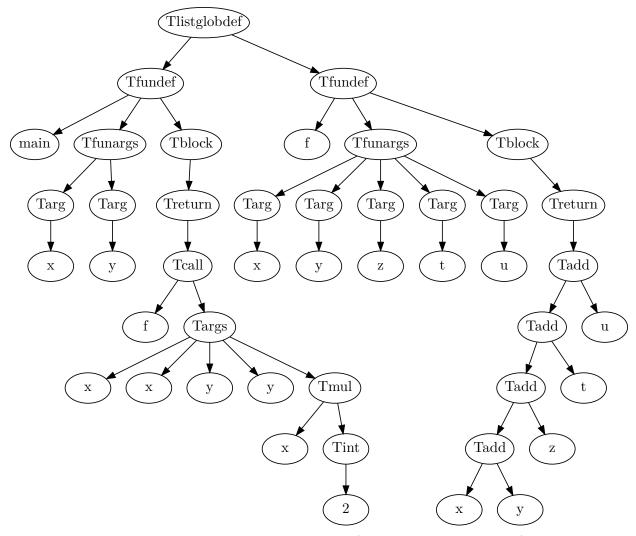
y = 8;

z = 5 * f(x,y) + 16; // Un appel de fonction, en tant qu'expression.
```

Étendez votre grammaire afin de reconnaître ces nouvelles constructions.

Écrivez également les actions correspondant à ces nouvelles constructions, de manière à obtenir un AST ressemblant à celui-ci :





Le programme source générant cet AST est le suivant (tests/funcall/5args.e):

```
main(x, y){
   return f(x,x,y,y,x*2);
}
f(x, y, z, t, u){
   return x + y + z + t + u;
}
```

Vous pouvez bien entendu ajouter au fichier src/ast.ml les nouveaux tags qui vous semblent nécessaires (Tcall, Targs...).

Conseils pour modifier la grammaire Il est important de vérifier que votre grammaire ne comporte pas de conflit, à chaque fois que vous la modifiez. Pour ce faire, deux solutions :

1. Lorsque vous lancez la commande make, la grammaire est recompilée et un message d'avertissement sera émis si un conflit est présent.



Warning! There is a conflict in your grammar. Check the prediction table for more details.

2. Comme le message d'avertissement vous le suggère, allez voir la table de prédiction pour identifier le conflit. Par défaut, la table est générée dans le fichier grammar.html à la racine de votre projet. Dans le dernier tableau du fichier, une case sur rouge indique un conflit. Cela signifie que l'analyseur syntaxique ne sait pas choisir la règle à appliquer pour continuer l'analyse.

Pour résoudre ces conflits, il faut notamment s'assurer qu'on n'a pas deux règles qui peuvent commencer par le même terminal. Il faut donc factoriser ces règles.

```
A -> X A { Node (Ta, [$1; $2])}
A -> X B { Node (Tb, [$1; $2])}
    devient alors

A -> X A_ou_B
A_ou_B -> A
A_ou_B -> B
```

Mais cela devient embêtant pour écrire les actions... On peut s'en sortir de différentes manières.

Solution 1 : définir des types Dans l'entête de la grammaire (avant le mot-clé rules et entre les accolades, où vous avez déjà dû écrire la fonction resolve\_associativity), vous pouvez définir un type spécifique à votre parseur :

```
{
  type mon_super_type =
  | MonSuperTypeA of tree
  | MonSuperTypeB of tree
}
...
A -> X A_ou_B {
  match $2 with
  | MonSuperTypeA t -> Node (Ta, [$1; t])
  | MonSuperTypeB t -> Node (Tb, [$1; t])
}
A_ou_B -> A { MonSuperTypeA $1 }
A_ou_B -> B { MonSuperTypeA $1 }
```

Avantages ça fonctionne aussi si on utilise A\_ou\_B à plusieurs endroits dans la grammaire Inconvénients c'est un peu lourd de définir de nouveaux types et de faire un match...

Solution 2 : renvoyer des fonctions Les actions peuvent être de n'importe quel type, y compris des fonctions!

On peut réécrire l'exemple précédent comme suit :

```
A -> X A_ou_B { $2 $1 }
A_ou_B -> A { fun x -> Node (Ta, [x; $1] }
A_ou_B -> B { fun x -> Node (Tb, [x; $1] }
```



Dans l'action de la première règle, on appelle la fonction renvoyée par le non-terminal A\_ou\_B avec, en argument, l'élément renvoyé par le non-terminal X.

Avantages plus élégant et plus court que la solution précédente

Inconvénients comme on a écrit toute la logique de l'action dans <code>A\_ou\_B</code>, on ne peut pas (à moins de passer d'autres arguments) utiliser ce non-terminal à plusieurs endroits, dans des contextes un peu différents.

## 10.2 Le langage E

Étendez les types des expressions et des instruction E de la manière suivante, dans src/elang.ml.

```
type expr =
...
| Ecall of string * expr list

type instr =
...
| Icall of string * expr list
```

Une expression Ecall(fname, args) représente un appel de la fonction nommée fname avec les arguments représentés par la liste d'expressions args. La valeur de cette expression est la valeur de retour de la fonction fname. Si la fonction ne renvoie pas de valeur, il s'agit d'une erreur.

De manière similaire, une instruction Icall(fname, args) représente un appel de la fonction nommée fname avec les arguments représentés par la liste d'expressions args. La valeur de retour de la fonction est ignorée.

### 10.2.1 Génération de E

Dans le fichier src/elang\_gen.ml, il vous faut maintenant traiter les nouveaux types de nœuds (Tcall, dans la figure précédente) introduits à la section précédente, afin de produire des expressions Ecall et des instructions Icall.

## 10.2.2 Interpréteur de E

Maintenant qu'une expression peut contenir des appels de fonctions, évaluer une expression peut nécessiter d'exécuter une fonction. Pour ce faire, vous allez avoir besoin d'écrire des définitions mutuellement récursives, c'est-à-dire que le corps de la fonction eval\_eexpr pourra faire appel à la fonction eval\_efun, qui appelle elle-même la fonction eval\_einstr, qui appelle elle-même la fonction eval\_eexpr...

La syntaxe OCaml pour écrire des définitions mutuellement récursive est la suivante :

```
and eval_einstr ... = ...
and eval_efun ... = ...
```



Il vous faudra sans doute ajouter des arguments à ces fonctions, notamment eval\_eexpr.

À noter : pour le moment, les fonctions ne modifient pas la mémoire – les seuls effets de bords que l'on peut observer sont des affichages à l'écran. Pour autant, en prévision de l'avenir, on supposera que la mémoire peut être modifiée et on prendra donc garde à propager l'effet des appels de fonction sur l'état du programme. Plus concrètement, si vous devez évaluer une liste [e1; e2] d'expressions (par exemple pour évaluer les arguments d'une fonction), gardez bien en tête que l'évaluation de e1 pourrait modifier l'état et donc influencer l'évaluation de e2. Le type de retour de la fonction eval\_eexpr pourrait donc être étendu...

# 10.3 Le langage CFG

Comme pour le langage E, on ajoute un nouveau type d'expression <code>Ecall(fname, args)</code> et un nouveau type de nœud <code>Ccall(fname, args, s)</code> où s est le successeur de ce nœud, comme dans <code>Cassign</code>.

Les changements à effectuer dans src/cfg\_run.ml sont similaires à ceux que vous aurez effectués dans src/elang\_run.ml.

Comme vos types de données ont changé, le compilateur va se plaindre que vos match ne sont pas exhaustifs. Contentez le compilateur en complétant ces match.

## 10.4 Le langage RTL

On introduit une opération Rcall of reg option \* string \* reg list.

L'opération Rcall(ord, fname, rargs) signifie qu'on appelle la fonction fname avec les arguments stockés dans les pseudo-registres rargs. Si ord = Some rd, le résultat de la fonction sera stocké dans le registre rd, sinon, si ord = None, le résultat de la fonction sera ignoré. Si org = Some rd mais que la fonction ne retourne pas de valeur, il s'agit d'une erreur.

## 10.5 Le langage LTL

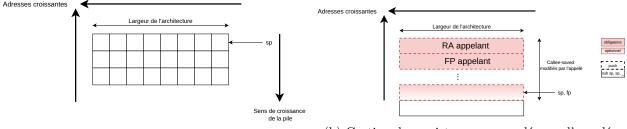
La plus grande difficulté pour traiter les appels de fonction se situe dans l'émission de code assembleur (ou LTL, c'est presque la même chose).

En effet, à cet endroit, on doit être en mesure d'appeler une fonction (via l'instruction Lcall(fname)), déjà présente dans src/ltl.ml. Mais il faut aussi, et surtout émettre le code assembleur qui :

- 1. sauvegarde les registres dits *caller-save* (*i.e.* ceux qui doivent être sauvegardés par l'appelant) : en effet, la fonction appelée va peut-être (sûrement) utiliser ces registres pour faire un calcul, et leur valeur dans la fonction appelante serait perdue;
- 2. fournit les arguments à la fonction;
- 3. effectue l'appel à proprement parler (instruction LCall);
- 4. récupère la valeur de retour de la fonction (stockée par convention dans le registre a0) à l'emplacement attendu (tel que calculé par l'allocation de registres);
- 5. restaure la valeur des registres caller-save.

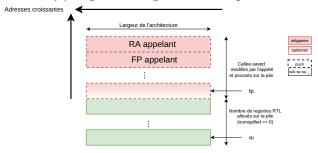
Les modifications que vous devez effectuer se situent dans le fichier src/ltl\_gen.ml dans la fonction ltl\_instrs\_of\_linear\_instr, où vous devez traiter le cas où l'instruction Linear que vous devez traduire est Rcall(rd, callee\_fname, rargs).





(a) Organisation générale de la pile.

(b) Gestion des registres sauvegardés par l'appelé.



(c) Gestion des registres RTL alloués sur la pile par l'allocateur de registres.

FIGURE 5 – Gestion de la pile en LTL et RiscV à l'entrée dans une fonction.

## 10.5.1 Sauvegarde des registres caller-save

Premièrement, il nous faut identifier l'ensemble des registres à sauvegarder. Une solution naïve consiste à sauvegarder tous les registres *caller-save*, à savoir les registres a0 à a7 et les registres t0 à t6. Dans votre code, cela s'écrirait arg\_register @ reg\_tmp.

Une solution plus économe serait de ne sauvegarder que les registres caller-save qui sont vivants après l'appel de fonction. Cette information est disponible via l'argument live\_out passé à la fonction ltl\_instrs\_of\_linear\_instr. L'ensemble des registres à sauvegarder est calculé par la fonction caller\_save, définie juste au-dessus de la fonction ltl\_instrs\_of\_linear\_instr. Cette fonction prend en paramètres :

- live\_out : le résultat de l'analyse de vivacité sur les arcs sortants;
- allocation: l'allocation de registres pour cette fonction;
- rargs : la liste des registres à passer en arguments.

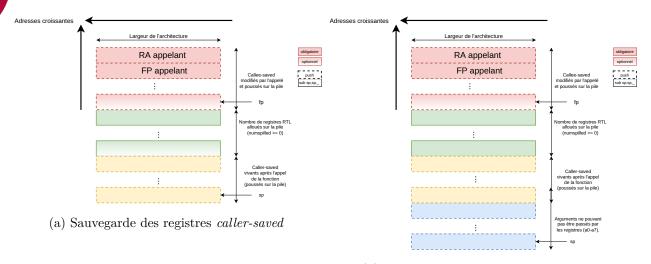
La raison pour laquelle on passe la liste des registres arguments est la suivante. Rappelez-vous que les arguments d'une fonction sont passés dans les registres a0 à a7 : le premier argument dans a0, le second dans a1, etc. Supposons que l'on ait un appel de fonction Linear f(r1,r2), et que r1 soit associé au registre a1 et r2 au registre a0 (c'est possible si r1 et r2 sont les arguments de la fonction appelante, comme illustré par le test tests/funcall/argswap.e).

Alors, lors du passage de paramètre (l'étape suivante), on va vouloir écrire a1 dans a0 et a0 dans a1. Si on fait naïvement :

```
mv a0, a1
mv a1, a0
```

alors, il est évident que la valeur contenue dans a1 ne sera pas la bonne, elle aura été écrasée par le my précédent.





(b) Passage des arguments surnuméraires

FIGURE 6 – Gestion de la pile en LTL et RiscV lors de l'appel d'une fonction.

C'est pourquoi la fonction caller\_save anticipe ce genre de problème, calcule l'ensemble des arguments qui vont être écrasés (fonction overwritten\_args) et les inclue dans l'ensemble des registres à sauvegarder.

Maintenant que les registres à sauvegarder sont identifiés, il faut émettre les instructions qui les sauvegardent. La fonction save\_caller\_save fait ce travail, et prend en paramètres :

- to\_save : ltl\_reg list : l'ensemble des variables à sauvegarder (on vient de le calculer!);
- ofs : int : le numéro du premier emplacement sur la pile disponible pour effectuer cette sauvegarde.

Si on reprend le schéma de la pile de la section précédente, et qu'on le complète.

L'emplacement prévu pour les sauvegardes de registres se situe à l'adresse pointée par s0, moins l'espace réservé aux registres évincés (spillés), moins l'espace réservé aux variables locales de la fonction.

Nous n'avons pas encore de variables locales à une fonction que nous stockons sur la pile, il nous suffit donc d'avoir le nombre de variables évincés, que l'on à notre disposition dans le paramètre num\_spilled de la fonction ltl\_instrs\_of\_linear\_instr.

La fonction save\_caller\_save renvoie un triplet (save\_regs\_instructions, arg\_saved, ofs), où:

- save\_regs\_instructions : ltl\_instr list est la liste des instructions LTL qui se chargent de sauvegarder les registres to\_save sur la pile;
- arg\_saved : (ltl\_reg \* int) list est une liste d'association : une paire (r, o) dans cette liste signifie que le registre LTL r a été sauvegardé à l'emplacement o de la pile (ofs pour le premier, ofs 1 pour le deuxième, etc.)
- ofs est le nouveau premier emplacement disponible sur la pile, après avoir sauvegardé les registres. Nous en aurons besoin pour la suite.

Après cette liste d'instructions, une série d'écritures à des adresses so - X ont été émises. Il faut à présent positionner le pointeur de pile sp juste après les registres sauvegardés : c'est là qu'on utilise la valeur ofs retournée par la fonction save\_caller\_save.



## 10.5.2 Passage des paramètres

Vient ensuite le moment du passage des paramètres. La fonction pass\_parameters, bien nommée, se charge de cette tâche. Elle prend en arguments :

- rargs: reg list: la liste des pseudo-registres RTL/Linear qui contiennent les arguments;
- allocation : l'allocation de registres ;
- arg\_saved : le résultat de save\_caller\_save, pour savoir où sont sauvegardés, si nécessaire, les arguments.

Elle peut échouer si certains registres de rargs ne sont pas alloués dans allocation. Si elle réussit, elle renvoie une paire (parameter\_passing\_instructions, npush), où :

- parameter\_passing\_instructions est une liste d'instructions LTL, qui effectuent le passage des paramètres;
- npush est le nombre d'arguments qu'on a du passer sur la pile. (La plupart du temps, les arguments iront dans les registres a0-7, mais pour des fonctions avec plus de 8 arguments (comme dans tests/funcall/lots\_of\_args.e par exemple), on utilisera la pile.)

Si nécessaire, cette fonction effectue des « push » sur la pile, c'est-à-dire qu'elle décrémente le registre sp et écrit à l'adresse obtenue.

## 10.5.3 Appel de la fonction

Ici, c'est très simple, il suffit d'émettre l'instruction LTL LCall callee\_fname, où callee fname est le nom de la fonction appelée.

### 10.5.4 Dépilement des arguments

On restaure le pointeur de pile sp juste avant les arguments, i.e. on replace le pointeur de pile npush emplacements plus haut dans la pile.

#### 10.5.5 Valeur de retour

La valeur de retour de la fonction est stockée dans a0, reportez-là à l'emplacement désiré (rd), si nécessaire.

## 10.5.6 Restauration des registres caller-save

Pour finir, il s'agit de restaurer la valeur des registres que l'on a sauvegardés. La fonction restore\_caller\_save calcule la liste des instructions qui effectuent cette tâche; elle prend en argument une liste d'association comme celle renvoyée par save\_caller\_save.

Attention, si l'emplacement correspondant au registre dans lequel on doit stocker la valeur de retour est un registre physique, il ne faudra pas restaurer la valeur de ce registre!

## 10.6 Fonctions built-in

Maintenant que vous êtes capables de gérer des appels de fonctions, vous remarquerez que l'instruction print est en fait un cas particulier d'appel de fonction. On peut donc supprimer l'instruction print de notre compilateur pour la transformer en un simple appel de fonction.

Voici les endroits où vous devrez apporter des modifications :

— le lexer : le token SYM\_PRINT n'a plus de raison d'être.



- la grammaire : un cas particulier n'est plus nécessaire.
- chacun des langages intermédiaires : plus besoin d'instruction dédiée à l'affichage!
- les interpréteurs de chacun de ces langages intermédiaires : on utilisera le mécanisme de built-in!

Le fichier src/builtins.ml contient un certain nombre de fonctions built-in prédéfinies pour vous. En particulier, la fonction do\_builtin oc mem fname vargs donne la sémantique de l'appel de la fonction built-in dont le nom est fname avec les arguments donnés dans vargs. Le paramètre oc est un output channel comme vous en avez déjà manipulé jusqu'ici. Le paramètre mem, de type Mem.t est une mémoire, dont vous n'avez pas encore eu besoin (mais très bientôt, promis!). Dans les interpréteurs des différents langages, vous pouvez passer la mémoire associée à l'état st comme ceci : st.mem.

Cette fonction a comme type de retour int option res:

- OK (Some i) signifie que la fonction s'est évaluée sans erreur et retourne la valeur entière i.
- OK None signifie que la fonction s'est évaluée sans erreur et ne retourne pas de valeur.
- Error msg signifie que la fonction s'est évaluée avec l'erreur msg.

# 10.7 Déboggage des programmes à bas niveau

À partir de maintenant, vous aurez peut être besoin de débogguer les programmes générés par votre compilateur afin de trouver des erreurs d'implémentation présents dans votre compilateur. Nous avons ajouté une nouvelle section (Appendix A) au sujet qui détaille comment procéder à la mise au point des programmes au niveau LTL et même RiscV.



# 11 Typage

Le but de cette extension de votre compilateur est d'ajouter des types à votre langage. Dans un premier temps, nous nous restreindrons aux type **int**, **char** et **void**. Dans les extensions ultérieures, nous ajouterons des pointeurs, des tableaux, des structures.

Un nouvel ensemble de fichiers de tests vous est proposé : les répertoires tests/type\_basic/, tests/type\_funcall/ et tests/char/. Jetez un œil à certains de ces fichiers avant de continuer votre lecture, pour vous familiariser avec le nouveau langage que vous allez devoir compiler.

Les types sont un concept de haut-niveau : c'est-à-dire qu'ils n'impactent que les quelques premiers langages intermédiaires. Dans notre cas, vous n'aurez qu'à modifier votre grammaire expr\_grammar\_action.g et les fichiers relatifs au langage E.

Pour commencer, ajoutez au fichier src/prog.ml les définitions suivantes :

```
type typ =
    Tint
    | Tchar
    | Tvoid

let string_of_typ t =
    match t with
    | Tint -> "int"
    | Tchar -> "char"
    | Tvoid -> "void"
```

On définit ainsi un type typ qui correspond aux différents types que nous allons supporter dans un premier temps. On définit également une fonction d'affichage de ces types.

Voici un aperçu des étapes que vous devrez franchir. Celles-ci sont volontairement peu détaillées pour laisser libre cours à votre imagination!

- 1. Modifiez votre grammaire pour supporter :
  - les types dans les signatures de fonction : type de retour et types des arguments
  - les déclarations de variables locales, suivies ou non, d'une initialisation (e.g. int x; ou int x = 3 \* z;)
  - les caractères litéraux : char c = 'A';
- 2. Ajoutez les définitions de tags nécessaires à src/ast.ml.
- 3. Ajoutez un constructeur Echar of char aux expressions de E (src/elang.ml).
- 4. Modifiez le type des fonctions efun dans src/elang.ml pour faire en sorte que :
  - funargs soit dorénavant une liste de string \* typ, pour retenir le type des arguments;
  - un nouveau champ funvartyp : (string, typ) Hashtbl.t enregistre le type de chaque variable locale;
  - un nouveau champ funrettype : typ donne le type de retour de la fonction.
- 5. Dans src/elang\_gen.ml, écrivez une fonction type\_expr (typ\_var : (string,typ) Hashtbl.t) (typ\_fun : (string, typ list \* typ) Hashtbl.t) (e: expr) : typ res qui calcule le type d'une expression.

  Les paramètres :
  - typ\_var donne le type de chaque variable locale de la fonction courante.



- typ\_fun donne la signature (type des arguments + type de retour) de chaque fonction déjà traitée dans le programme.
- e est l'expression à typer.

La fonction renvoie une erreur, notamment si une variable ou une fonction apparaissant dans l'expression n'a pas de type connu.

- 6. Toujours dans src/elang\_gen.ml, ajoutez les paramètres typ\_var et typ\_fun aux fonctions make\_eexpr\_of\_ast et make\_einstr\_of\_ast. Vérifiez (avec un appel à type\_expr) que les expressions construites ont un type, avant de les renvoyer dans make\_eexpr\_of\_ast.
  - Dans make\_einstr\_of\_ast, vérifiez que lors d'une affectation v = e, la variable v et l'expression e ont des types compatibles. (int et char sont compatibles, int et void non). (Écrivez une fonction séparée pour tester la compatibilité de 2 types.)
  - Toujours dans make\_einstr\_of\_ast, mettez à jour typ\_var lorsque vous rencontrez une déclaration de variable. Vérifiez au passage qu'on ne déclare pas de variable de type void.
  - Lors d'appels de fonctions (que ce soit comme une expression <code>Ecall</code> ou une instruction <code>Icall</code>), vérifiez que les arguments sont du type attendu (comparez avec la signature que vous pouvez obtenir via <code>typ\_fun</code>).
- 7. Dans la fonction make\_fundef\_of\_ast, initialisez une table typ\_var puis mettez à jour la table typ\_fun que vous devrez recevoir en argument.
- 8. Dans la fonction make\_eprog\_of\_ast, initialisez la table fun\_typ en y insérant notamment le type de trois fonctions built-in utiles :

```
let fun_typ = Hashtbl.create (List.length 1) in
Hashtbl.replace fun_typ "print" ([Tint], Tvoid);
Hashtbl.replace fun_typ "print_int" ([Tint], Tvoid);
Hashtbl.replace fun_typ "print_char" ([Tchar], Tvoid);
```

9. On remarque qu'il faut avoir défini une fonction pour qu'on puisse l'appeler dans une autre. (Le typage devrait échouer si ce n'est pas le cas.)

Comment gérer les fonctions mutuellement récursives? Regardez les fichiers tests/type\_funcall/mutrec.e et tests/type\_funcall/mutrec-hotstadter.e. Ils contiennent des déclarations de fonctions. Faites-en sorte de traiter ces fichiers convenablement. (L'évaluation du fichier tests/type\_funcall/mutrec-hotstadter.e prend un certain temps...)



## 12 Pointeurs

Nous allons maintenant ajouter des **pointeurs** à notre langage. Regardez notamment les tests dans le répertoire tests/ptr/. Ces programmes introduisent deux nouvelles constructions : l'opérateur & qui représente l'adresse d'une variable, et l'opérateur de déréférencement \*.

Ainsi, le programme suivant, lancé avec les paramètres x=14 et y=12, devrait renvoyer la valeur 26:

```
void f(int* z, int x, int y){
  *z = x + y;
}
int main(int x, int y){
  int z = 3;
  f(&z, x, y);
  return z;
}
```

En effet, on passe l'adresse de z, ainsi que les valeurs de x et y à la fonction f. Cette fonction écrit à l'adresse contenue dans z, la somme de x et y. La fonction main finit par renvoyer la valeur de z, qui devrait contenir 26.

Ces nouveaux opérateurs engendrent les modifications suivantes dans notre compilateur :

- la grammaire doit reconnaître ces nouveaux opérateurs (d'ailleurs l'analyseur lexical doit aussi reconnaître le nouveau token & pourquoi ne pas l'appeler SYM\_AMPERSAND?)
- les types (dans src/prog.ml) sont enrichis avec un nouveau constructeur Tptr ty : un pointeur sur des éléments de type ty.
- on ajoute au langage E (fichier src/elang.ml):
  - une expression Eaddrof of expr pour symboliser l'expression &e
  - une expression **Eload** of expr pour symboliser l'expression \*e
  - une instruction Istore of expr \* expr pour symboliser l'instruction \*e = v;

De plus, une fonction (type efun) contient deux nouveaux champs:

- un champ funvarinmem : (string, int) Hashtbl.t qui associe chaque nom de variable qui doit résider en mémoire un déplacement dans le bloc de pile associé à chaque activation de cette fonction
- un champ funstksz: int qui donne la taille du bloc de pile de cette fonction.

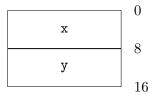
Ces derniers éléments méritent un peu d'explications. Supposons que vous ayez le code C suivant :

```
int f(){
  int x = 3;
  int y = 4;
  int z = 5;
  z = g(&y, &x);
  return z;
}
```



Dans cet exemple, on utilise l'opérateur & sur les variables  $\mathbf{x}$  et  $\mathbf{y}$ : ces variables ont donc besoin d'êtres alloués en mémoire, plus précisément sur la pile puisque ce sont des variables locales à la fonction  $\mathbf{f}$ . En revanche, la variable  $\mathbf{z}$  peut rester, comme l'étaient toutes les variables jusqu'à présent, des temporaires qui ne sont pas allouées en mémoire.

On aura donc pour cet exemple un bloc de pile de 16 octets (à supposer que les **int** sont codés sur 8 octets).



Ici, la table funvarinmem associera la variable x au déplacement (ou offset) 0 et la variable y au déplacement 8. Le champ funstksz vaudra 16.

### 12.1 Génération de E

Lors des séances précédentes, vous avez dû ajouter une fonction type\_expr à src/elang\_gen.ml. Assurez-vous de mettre à jour le typage concernant les pointeurs. On notera que p + i, i + p et p - i ont le même type que p lorsque p est un pointeur et i est un entier (ou un caractère, d'ailleurs). Étant donnés 2 pointeurs p et q de même type, on peut également comparer ces pointeurs et obtenir un entier. Toutes les autres opérations unaires et binaire sont indéfinies.

Comme on l'a vu précédemment, certaines variables seront allouées sur la pile et d'autres dans des temporaires. Le critère est le suivant : si l'adresse d'une variable est prise dans le programme (au moyen de l'opérateur &), alors cette variable sera allouée dans la pile. (Plus tard, on ajoutera à la pile les variables non-scalaires, *i.e.* les tableaux ou les structures.)

Écrivez une fonction addr\_taken\_expr (e: expr) : string Set.t qui récolte l'ensemble des variables dont l'adresse est prise dans une expression e. Faites de même pour les instructions avec une fonction addr\_taken\_instr (i: instr) : string Set.t.

Dans la fonction make\_fundef\_of\_ast, initialisez une table de hachage funvarinmem qui associe à chaque variable allouée sur la pile un offset (déplacement) dans le bloc de pile associé à cette fonction. Pour ce faire, vous aurez besoin de définir une fonction size\_type (t: typ) : int res qui renvoie la taille occupée en mémoire par une variable de type t. Définissez cette fonction dans src/prog.ml.

### 12.1.1 Interpréteur de E

Les différentes fonctions de l'interpréteur E prennent un argument supplémentaire : un pointeur de pile sp : int qui donne l'adresse de départ du bloc de pile dans la mémoire.

Ce pointeur de pile sera notamment utile pour les expressions **Eaddrof** et **Eload**, ainsi que pour les instructions **Istore**.

La mémoire est accessible depuis l'état st via st.mem. Les différentes opérations intéressantes sur la mémoire sont les suivantes :

— Mem.write\_bytes (m: Mem.t) (addr: int) (bytes: int list) : unit res. Cette fonction écrit dans la mémoire m à l'adresse addr la liste d'octets bytes. Renvoie OK () si tout s'est bien passé, Error msg sinon (accès hors des bornes de la mémoire).



Cette fonction est utilisée en conjonction avec la fonction split\_bytes n v qui découpe un entier v en n morceaux (chacun de la taille d'un octet).

— Mem.read\_bytes\_as\_int (m: Mem.t) (addr: int) (sz: int) : int res. Cette fonction lit dans la mémoire m aux adresses [addr; addr + sz[ et renvoie l'entier représenté par ces octets.

Pour l'évaluation des opérateurs binaires, attention aux additions et soustractions sur les pointeurs. Soit un pointeur p de type **Tptr** t et un entier i :

- l'expression p + i s'évalue en fait en p + i \* sizeof(t)
- l'expression p i s'évalue en fait en p i \* sizeof(t)
- l'expression i + p s'évalue en fait en i \* sizeof(t) + p

Attention aussi aux expressions **Evar** v et aux instructions **Iassign**(v,e) : la variable est peut-être en mémoire et il faut y accéder correctement!

Notez aussi qu'on ne peut pour l'instant appliquer l'opérateur & que sur des variables, et éventuellement sur des expressions **Eload e**.

Pour savoir combien d'octets lire ou écrire (expressions **Eload addr** et instructions **Istore**(addr, v)), référez-vous au type de l'expression addr et à la taille du type pointé.

Dans la fonction eval\_efun, réservez la place nécessaire sur la pile en ajustant sp comme nécessaire.

Vous aurez besoin de typage, donc de la fonction type\_expr définie dans src/elang\_gen.ml. N'oubliez pas d'ajouter un open Elang\_gen en haut de votre fichier. Vous aurez également besoin d'une table typ\_fun que vous pouvez initialiser dans eval\_eprog et propager dans les différentes fonctions. Pour la table typ\_var, vous devriez trouver votre bonheur dans les champs des fonctions (type efun).

## 12.2 Génération de CFG

Dans le langage CFG, on se débarasse des informations de typage. On ajoute, dans le fichier src/cfg.ml :

- une expression **Estk of int**, qui représente une adresse dans le bloc de pile de la fonction courante;
- une expression Eload of expr \* int. Eload(e, sz) représente une lecture en mémoire à l'adresse représentée par e, sur sz octets
- une instruction Cstore of expr \* expr \* int \* int. Cstore(addr, v, sz, succ) représente une écriture en mémoire à l'adresse représentée par l'expression addr, la valeur que l'on écrit est celle de l'expression v sur sz octets. Le successeur de cette instruction est succ, comme pour l'instruction Cassign par exemple.
- un champ cfgfunstksz : int au type des fonctions CFG cfg\_fun.

La compilation des expressions et instructions E en expressions et nœuds CFG imite l'interpréteur de E que vous venez d'écrire. Il vous faudra donc effectuer les mêmes vérifications de type, ajuster les opérations sur les pointeurs, transformer les Evar v et les affectations Iassign(v,e) en lectures et écritures sur la pile lorsque cela est nécessaire.

## 12.3 Interpréteur de CFG

De manière similaire au langage E, le langage CFG va avoir besoin d'un pointeur de pile sp pour évaluer nos nouvelles expressions et instructions.



### 12.4 RTL

Ajoutez à src/rtl.ml les opérations :

- Rstk of reg \* int : Rstk(rd, i) écrit dans le registre rd l'adresse située à un déplacement i du début du bloc de pile.
- Rload of reg \* reg \* int: Rload(rd, rs, sz) stocke dans le registre rd la valeur sur sz octets lue à l'adresse contenue dans rs
- Rstore of reg \* reg \* int: Rstore(rd, rs, sz) écrit la valeur contenue dans rs sur sz octets à l'adresse contenue dans rd.

On ajoute également un champ rtlfunstksz : int aux fonctions rtl\_fun. Adaptez l'interpréteur comme vu avant.

## 12.5 Linear

Comme Linear partage l'ensemble des opérations RTL, il suffit d'ajouter dans src/linear.ml un champ linearfunstksz au type des fonctions.

Adaptez l'interpréteur comme vu avant.

### 12.6 LTL

La fonction ltl\_instrs\_of\_linear\_instr prend un nouvel argument numlocals : int : il s'agit du nombre d'emplacements sur la pile qu'il faut réserver pour les variables locales. Ce nombre sera calculé dans la fonction ltl\_fun\_of\_linear\_fun en fonction de la taille linearfunstksz de la fonction Linear. Attention, on doit passer d'un nombre d'octets (linearfunstksz) à un nombre d'emplacements (de taille !Archi.wordsize, soit 8 en 64 bits ou 4 en 32 bits).

Propagez cette valeur où cela vous semble nécessaire pour respecter les schémas de la Figure 5. Assurez-vous également de compiler comme il se doit les instructions Rstk, Rload et Rstore.

Dans la fonction ltl\_fun\_of\_linear\_fun, adaptez le *prologue* de la fonction pour réserver de l'espace pour les variables stockées sur la pile.



## 13 Structures

Nous nous intéressons maintenant aux **structures**. Nous souhaitons être en mesure de compiler des programmes comme le suivant :

```
struct mastruct {
     int x;
     int y;
   };
4
5
   int main(){
6
     struct mastruct S;
     S.x = 12;
     S.y = 3;
9
     return (S.x + S.y);
10
   }
11
```

Ce test est donné dans tests/structs/struct.e.

Voici un aperçu des changements à effectuer.

## 13.1 La grammaire

Modifiez la grammaire pour autoriser des définitions de type de structure, comme dans les lignes 1 à 4 du test ci-dessus. Un fichier devient alors une liste de définitions globales, chaque définition étant soit une définition de fonction, soit une définition de type de structure.

Permettez aussi aux fonctions de prendre des arguments de type « structure », et les définitions de variables locales de type « structure ».

## 13.2 Le langage E

Ajoutez au langage E:

- une expression **Egetfield** of expr \* string : **Egetfield**(e, f) représente un accès au champ f de la structure dont l'adresse est représentée par l'expression e
- une instruction Isetfield of expr \* string \* expr : Isetfield(s, f, e) représente une écriture de l'expression e dans le champ f de la structure dont l'adresse est représentée par l'expression e.

Aussi, le type eprog devient :

```
type eprog = efun prog * (string, (string * typ) list) Hashtbl.t
```

La deuxième composante de la paire est une table de hachage qui donne, pour chaque type de structure, la liste des champs de la structure avec leurs types. Cela nous sera utile, notamment pour connaître la disposition des champs au sein des structures.

## 13.3 Le fichier src/prog.ml

Dans src/prog.ml, ajouter un nouveau constructeur à typ pour les types de structures : Tstruct of string (le paramètre de type string est le nom de la structure).



Adaptez la fonction size\_type pour calculer la taille des structures. Ajoutez-y comme argument une table de hachage comme celle décrite ci-dessus. Par exemple, la taille de la structure mastruct dans l'exemple précédent est 16 (2 champs de taille 8).

Ajoutez également les deux fonctions suivantes :

```
— let rec field_offset
   (structs: (string, (string * typ) list) Hashtbl.t)
   (s: string) (f: string) : int res
```

Un appel à field\_offset structs s f renvoie l'offset du champ f dans une structure de type s. Par exemple, field\_offset structs "mastruct" "x" renverra OK 0 et field\_offset structs "mastruct" "y" renverra OK 8. Un appel erroné field\_offset structs "mastruct" "z" renverra Error "No such field 'z'", ou un message d'erreur similaire dans la langue de votre choix.

```
— let rec field_type
    (structs: (string, (string * typ) list) Hashtbl.t)
    (s: string) (f: string) : typ res
```

Un appel à field\_type structs s f renvoie le type du champ f dans une structure de type s. Par exemple, field\_type structs "mastruct" "x" et field\_type structs "mastruct" "y" renverront OK Tint.

#### 13.4 Génération de E

Dans src/elang\_gen.ml, ajoutez un argument typ\_struct : (string, (string \* typ) list) Hashtbl.t aux fonctions type\_expr, make\_eexpr\_of\_ast, make\_einstr\_of\_ast.

Modifiez la fonction make\_fundef\_of\_ast pour qu'elle traite aussi les définitions de types structure. Sa tâche sera alors d'augmenter la table typ\_struct lorsqu'une définition de structure est rencontrée.

Lors de la construction de l'ensemble funvarinmem des variables locales qui doivent aller dans la mémoire, ajoutez, en plus des variables dont on prend l'adresse, les variables de type struct. En effet, celles-ci doivent être allouées en mémoire. D'une manière plus générale, on mettra en mémoire toutes les variables qui ne sont pas scalaires, c'est-à-dire de type simple (entier, pointeur, caractère).

Il faudra aussi, évidemment, modifier les fonctions type\_expr et make\_eexpr\_of\_ast pour typer et générer des expressions E Egetfield, et la fonction make\_einstr\_of\_ast pour générer des instructions Isetfield. Faites bien attention à donner comme premier paramètre de Egetfield et Isetfield l'adresse de la structure : introduisez éventuellement un Eaddrof...

# 13.5 Interpréteur de E

Dans src/elang\_run.ml, ajoutez aussi un paramètre typ\_struct là où cela vous semble nécessaire, du même type que précédemment. Vous instancierez ce paramètre avec la table générée dans src/elang\_gen.ml.

Cela vous permettra d'évaluer les accès en lecture et écriture aux champs d'une structure. Vérifiez, dans l'interpréteur que lors de l'évaluation de Egetfield(e,f) ou Isetfield(e,f,v), l'expression e est bien de type Tptr (Tstruct structname). Les fonctions field\_offset et field\_type définies plus haut dans src/prog.ml devraient vous être utiles.



Pour l'évaluation de **Egetfield(e,f)**, si le champ est de type *scalaire* (entier, pointeur, caractère), lisez la valeur contenue en mémoire. Sinon, s'il s'agit d'une structure, renvoyez simplement l'adresse de ce champ.

## 13.6 Génération de CFG

Dans src/cfg\_gen.ml, ajoutez aussi un paramètre typ\_struct, encore du même type que précédemment, là encore, là où cela vous semble pertinent. Vous instancierez ce paramètre avec la table générée dans src/elang\_gen.ml.

On n'ajoute pas d'expressions ou d'instructions spécifiques aux structures dans le langage CFG. On va simplement transformer les accès aux champs des structures en simples accès à la mémoire.

Ainsi, on remplacera la lecture S.y en \*(&S + 8) par exemple. L'adresse de S aura aussi été remplacée par un emplacement sur la pile : cela donnera donc en fait \*(stk(0) + 8) ou quelque chose de similaire.

Une fois cette transformation effectuée, nul besoin de modifier le reste du compilateur, il doit normalement déjà savoir gérer les lectures et écritures en mémoire.



## 14 Tableaux

Nous ajoutons maintenant les tableaux!

Voici un exemple de programme utilisant des tableaux (tests/array/array.e)

```
int main(){
  int t[10];
  t[0] = 5;
  t[1] = 3 + t[0];
  return t[1];
}
```

On déclare un tableau de 10 entiers, on initialise la première case à 5, la deuxième à la valeur de la première plus 3, puis on renvoie la valeur de cette deuxième case. Le résultat attendu, sans suprise, est 8.

## 14.1 La grammaire

Étendez la grammaire pour être capables de déclarer des variables de type « tableau », et d'y accéder en lecture et écriture (t[i]).

## 14.2 Génération et interpréteur de E

Ajoutez un type dans src/prog.ml qui représente les tableaux : Ttab of typ \* int : Ttab(ty,n) représente un tableau de n éléments, chacun de type ty.

On notera que les types <code>Ttab(ty, n)</code> et <code>Tptr ty</code> sont compatibles, c'est-à-dire, on peut donner un paramètre de type <code>Ttab(ty,n)</code> à une fonction qui attend un argument de type <code>Tptr ty</code>. On modifiera donc l'évaluation des expressions, notamment pour que les additions et soustractions se comportent avec les tableaux comme avec les pointeurs.

Transformez les accès à des tableaux en simples accès à la mémoire. Ainsi, l'accès t[i] est transformé en \*(t + i). Nul besoin ici de multiplier i par la taille des éléments pointés par t, cette transformation est normalement déjà faite dans l'évaluation de l'addition entre pointeurs et entiers.

De la même manière que pour les structures, lors de l'évaluation d'un **Eload(e)**, si le type pointé par **e** est un scalaire, on rendra sa valeur en mémoire, mais s'il s'agit d'un type structure ou tableau, on rendra simplement son adresse.

## 14.3 Génération de CFG

Comme pour l'évaluation de E, il faut traiter les tableaux comme des pointeurs lors des additions et soustractions. C'est tout ce qu'il faut modifier!



# 15 Variables globales

On s'attaque maintenant aux variables globales. Effectivement, jusqu'à présent, toutes les données que nous pouvions manipuler étaient des variables locales à une fonction. Voici un exemple de programme utilisant des variables globales (tests/globals/globarray.e):

```
int max = 20;
int objs[20];
int main(){
  int i = 0;
  int sum = 0;
  while (i < max){</pre>
    objs[i] = sum;
    sum = sum + i;
    i = i + 1;
  }
  i = 0;
  while (i < max){
    print(objs[i]);
    i = i + 1;
  }
  return objs[max-1];
}
```

On y définit deux variables globales : un entier max et objs, un tableau de 20 entiers.

On stocke dans chaque case i du tableau la somme des entiers de 1 à i, puis on affiche chacune des 20 cases du tableau. La sortie attendue est la suivante :

```
0
0
1
3
6
10
15
21
28
36
45
55
66
78
91
105
120
136
153
```

171



## 15.1 La grammaire

Étendez la grammaire pour permettre la définition de variables globales, avec ou sans initialisation. Attention à ne pas générer de conflit dans votre grammaire.

## 15.2 Le langage E

Ajoutez une expression **Eglobvar of string** aux expressions E. L'expression **Eglobvar "max"** contient l'adresse en mémoire de la variable globale nommée "max". Effectivement, toutes les variables globales sont stockées en mémoire. On verra par la suite comment les initialiser.

## 15.3 Génération de E

De la même manière que vous avez ajouté un paramètre typ\_struct pour les structures, ajoutez un paramètre typ\_glob : (string, typ) Hashtbl.t à chaque fonction qui en a besoin (type\_expr, make\_eexpr\_of\_ast, make\_einstr\_of\_ast...).

Vous devrez différencier, lorsque vous rencontrez un identifiant de variable, s'il s'agit d'une variable locale (Evar v) ou globale (Eglobvar v). Utilisez les informations de typage (typ\_var et typ\_glob) pour ce faire.

L'initialisation d'une variable globale doit être une constante, de type entier ou caractère. En cas d'absence d'initialiseur, on se contentera de réserver de l'espace.

Pour caractériser cela, ajoutez à src/prog.ml le type suivant :

```
type init_data =
    | Iint of int
    | Ichar of char
    | Ispace of int
```

On changera également la définition du type gdef pour y ajouter un constructeur Gvar of typ \* init\_data.

Par exemple les deux définitions globales de l'exemple en début de section généreront les définitions globales suivantes : Gvar(Tint, Iint 20) et Gvar(Ttab(Tint, 20), Ispace(160)) (parce que 20 \* 8 = 160).

Modifiez la fonction make\_fundef\_of\_ast pour traiter les définitions de variables globales. Au passage, renommez-là en make\_globdef\_of\_ast et changez son type de retour en remplaçant (string \* efun) par (string \* efun gdef).

## 15.4 Interpréteur de E

Ajoutez un champ glob\_env: (string, 'a) Hashtbl.t au type state dans src/prog.ml, qui recueillera les adresses des différentes variables globales.

Enfin, ajoutez, toujours dans ce fichier, une fonction

```
let init_glob
    (mem: Mem.t) (glob_env: (string, int) Hashtbl.t)
    (p: 'a prog) (startglob: int) : int res = ...
```

qui, étant donnés un programme p et une adresse de départ startglob, construit (enrichit) un environnement global glob\_env et écrit dans la mémoire mem. Pour ce faire, on itèrera sur les définitions du programme p (en ignorant les définitions de fonctions) et on écrira l'entier ou le



caractère d'initialisation de la globale en question, ou bien on se contentera de réserver de l'espace si l'initialiseur est Ispace n.

Ajoutez dans src/elang\_run.ml un paramètre typ\_glob là où cela vous semble nécessaire. L'évaluation de l'expression Eglobvar v devrait être similaire au cas Evar v, sauf que vous chercherez dans l'environnement global plutôt que dans l'environnement local et que les variables sont toujours allouées dans la mémoire.

Dans la fonction eval\_prog, lorsque vous itérez sur les définitions du programme et que vous tombez sur une variable globale, il faut mettre à jour son type dans la table typ\_glob. Aussi, appelez la fonction init\_state que vous avez définie dans src/prog.ml. Vous pouvez utiliser, par exemple, l'adresse 0x1000 comme adresse de départ des globales. (Le choix de cette adresse n'a pas vraiment d'influence. Il faut simplement qu'on ait suffisamment de place pour y stocker l'ensemble des variables globales et que ça n'entre pas en conflit avec la pile. Lorsque vous lancez votre compilateur, la taille de la mémoire est par défaut de 10000 (soit 0x2710). Allouer les globales à 0x1000 devrait ne pas poser de problème pour l'ensemble des tests qui vous sont proposés. La « vraie » allocation, pour les programmes RISC-V sera faite par le linker pour vous, avec davantage de distance entre les différentes zones de la mémoire.)

## 15.5 Génération de CFG

Répétez plus ou moins les mêmes opérations que pour l'interpréteur de E : ajoutez un champ typ\_glob, ajoutez une expression Eglobvar of string, étendez typ\_glob dans la fonction cfg\_prog\_of\_eprog pour y ajouter le type des globales.

# 15.6 Autres langages intermédiaires

Pour RTL, ajoutez une opération Rglobvar of reg \* string. L'opération Rglobvar (rd, v) met l'adresse de la globale v dans le registre rd.

Pour LTL, ajoutez une opération LGlobvar of ltl\_reg \* string, cette fois ci avec un registre machine.

Pour chacune des passes de compilation, il faut aussi propager les définitions globales. Il suffit de les laisser inchangées (pas besoin de les compiler).

On ajoutera également à l'état des programmes RTL et Linear un champ glob\_env de la même nature que celui défini pour E et CFG dans le type state de src/prog.ml, et encore de manière similaire pour les programmes LTL dans src/ltl\_run.ml.

Dans src/riscv.ml, compilez l'opération LGlobvar(rd, s) grâce à l'instruction RISC-V la rd, symbol, qui écrit l'adresse du symbol dans le registre rd.

Toujours dans src/riscv.ml, il faut déclarer les variables globales que vous utilisez dans une section .data, que l'on déclare en écrivant .section .data. Pour chaque variable, si elle est initialisée, il faut donner son contenu sous forme d'une liste d'octets (on pourra utiliser la fonction split\_bytes, déjà décrite dans ce document). Si elle n'est pas initialisée, on y mettra des octets nuls.

Par exemple:

```
.section .data
max:
    .byte 20,0,0,0,0,0,0
objs:
    .zero 160
```



# 16 Space Invaders!

Pour terminer ce projet de compilation en apothéose, nous vous proposons de jouer à un jeu vidéo dernier cri (1978) qui nous vient de la société japonaise Taito :  $\cancel{\cancel{-}} \cancel{\cancel{-}} \cancel$ 

Vous trouverez le code source de ce jeu dans le répertoire tests/invader.e. De nouvelles constructions du langage vous empêcheront de le compiler directement. À vous de vous débrouiller pour traiter ces nouvelles constructions.

# 16.1 Nouvelles constructions du langage

En particulier, vous devrez traiter :

- les nombres hexadécimaux comme 0x123aBc12F. (Vous ne devrez toucher qu'au fichier src/e\_regexp.ml pour cela.)
- les opérateurs booléens comme && et | |.
  - En vrai C, l'expression e1 && e2 sera évaluée de la façon suivante. On évalue e1 : si sa valeur est fausse (0), alors on n'évalue pas e2 (qui peut contenir des effets de bord) et on retourne 0. Sinon, on retourne 0 si e2 vaut 0, et 1 sinon.
  - De manière similaire, lors de l'évaluation de e1 || e2, on n'évalue pas e2 si e1 vaut vrai (!= 0).
  - Cela étant dit, en première approximation, vous pourrez évaluer les deux opérandes et en calculer le ET / OU booléen, à l'aide des instructions RISC-V and et or, en notant bien que ceci ne fonctionne que lorsque les expressions e1 et e2 s'évaluent en 0 ou en 1. À moins d'une erreur de notre part, le code dans invader.e et le code de src/riscv.ml respectent cette convention.
- l'opérateur ET bit-à-bit &. Vous pourrez utiliser la fonction land : int -> int qui effectue cette opération sur les entiers OCaml, et l'instruction RISC-V and.
- l'opérateur NON logique!. Vous utiliserez l'instruction RISC-V seqz rd, rs qui écrit la valeur 1 dans rd si rs vaut 0, et la valeur 0 dans rd sinon.

## 16.2 Compilation

La première étape pour compiler ce programme est d'émettre du code assembleur. Dans le répertoire tests/invader/:

```
$ ../../main.native -f invader.e -m32 -nostart -clever-regalloc -no-dot -json /dev/null
```

Cette commande produit le fichier tests/invader/invader.s qui contient le code assembleur de cette application.

L'option -nostart indique que le symbole \_start, point d'entrée du programme, ne doit pas figurer dans le code généré. En effet celui-ci apparaît dans une librairie que nous allons lier à notre programme tout de suite :

```
$ riscv32-unknown-elf-gcc -march=rv32im -mabi=ilp32 \
-I. -I./include -g -DENV_QEMU=1 -T ./extended.lds \
-nostartfiles -nostdlib -nostdlic -static \
invader.s crt.s setup.c font.c libscreen.c libfemto.a itoa.c \
-o invader
```



Vous devriez obtenir un exécutable RISC-V, ce que vous pouvez vérifier de la manière suivante :

```
$ file invader invader: ELF 32-bit LSB executable, UCB RISC-V, version 1 (SYSV), statically linked, with \hookrightarrow debug_info, not stripped
```

## 16.3 Exécution

Vous avez un exécutable, mais vous ne savez pas exécuter des binaires RISC-V. Oh non! Il ne vous reste plus qu'à vous procurer sur eBay une machine du type suivant :



Mais non! On va pouvoir utiliser un émulateur de processeur RISC-V. Nous vous avons préparé une installation de **qemu** spécifique dans un conteneur docker. Pour installer docker sur Ubuntu ou Debian :

```
$ sudo apt install docker.io xtightvncviewer
```

Vous pouvez ensuite récupérer l'image docker préparée pour vous :

```
$ docker pull pwilke/qemu-compil:latest
```

Placez-vous maintenant dans le répertoire tests/invader, où vous avez généré le binaire RISC-V invader.

```
$ docker run --rm -v $(pwd):/data -p 5900:5900 -it qemu-compil invader
```



Ah, mais ça n'affiche rien!

Oui, en fait l'image est envoyée dans un socket VNC (Virtual Network Computing). (On aurait sans doute pu afficher directement sur votre écran, mais de manière non portable.)

Il faut donc se connecter avec un client VNC.

Si vous êtes sous Linux, on vous a fait installer un client VNC ci-dessus, il suffira de lancer ceci :

#### \$ vncviewer 127.0.0.1:5900

Si vous êtes sous Windows ou Mac OS, télécharger un client VNC (https://www.clubic.com/telecharger-fiche46296-vnc-viewer.html a l'air formidable.)

Youpi! (Enfin youpi si ça fonctionne...)



# A Déboggage des programmes au niveau des langages bas niveau

## A.1 Déboggage d'un programme au niveau du langage LTL

Il est possible de demander à l'interpréteur du langage LTL de passer dans un mode de déboggage via une option particulière (-ltl-debug) de la ligne de commande du compilateur. Dans ce cas, le compilateur ne rend pas la main et attend des commandes provenant d'un logiciel extérieur sur une websocket <sup>5</sup> en écoute à l'adresse IP 127.0.0.1 sur le port 8080.

Nous vous fournissons le programme externe qui va agir comme un déboggueur. Celui-ci est écrit en Javascript. Son code est situé dans le répertoire ldb/.

Ainsi pour débogguer au niveau du langage LTL le code produit par votre compilateur à partir du code source tests/mes-tests/file.e, il suffit d'entrer la commande suivante dans un terminal :

## \$ ./main.native -f tests/mes-tests/file.e -ltl-debug

Puis dans un second terminal, ou un nouvel onglet de votre terminal:

#### \$ firefox ldb/ldb.html

Vous verrez alors apparaître une fenêtre qui ressemble à celle illustrée par la figure 7. Cette

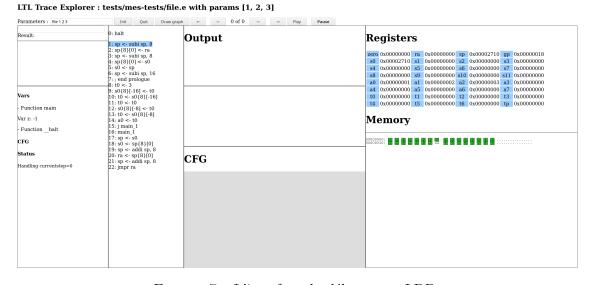


FIGURE 7 – L'interface du déboggueur LDB.

fenêtre permet de piloter l'interpréteur LTL intégré au compilateur.

# A.2 Déboggage d'un programme au niveau du langage RiscV

<sup>5.</sup> Une websocket est une socket TCP qui peut être ouverte depuis un navigateur Web pour se connecter à un site distant avec cependant des restrictions de sécurité. Le flux TCP transporte un protocole dédié qui peut-être décodé sous la forme d'objets JSON depuis un script Javascript s'exécutant dans le navigateur.



Parameters: file 1 2 3	Init
(a) Paramètres à passer au programme.	(b) Initialisation de l'interpréteur.
<b>→</b>	<b>←</b>
(c) Avancer d'une instruction.	(d) Revenir en arrière d'une instruction.
→	4-

(e) Exécuter le programme jusqu'au prochain point (f) Revenir en arrière dans la trace jusqu'au précédent d'arrêt ou la fin du programme.

point d'arrêt ou au début du programme.

Memory	Memory
00000000: 90 90 90 90 90 90 90 90 90 90 90 90 90	00000000: 90 90 90 90 90 90 90 90 90 90 90 90 90
000026f0: <b>000 000 000 000 000 000 000 000 000 </b>	00002660: 03 00 00 00 00 00 00 00 00 00 00 00 00

(g) Lecture d'une zone mémoire.

(h) Écriture d'une zone mémoire.

FIGURE 8 – Quelques éléments de l'interface graphique du déboggueur LDB.

```
0: halt
                                                                                                                                                  0: halt
1: sp <- subi sp, 8

2: sp{8}[0] <- ra

3: sp <- subi sp, 8

4: sp{8}[0] <- s0

5: s0 <- sp

6: sp <- subi sp, 16

7: ; end prologue

8: t0 <- 3
                                                                                                                                                  1: sp <- subi sp, 8
2: sp{8}[0] <- ra
3: sp <- subi sp, 8
                                                                                                                                                 4: sp {8}[0] <- s0

5: s0 <- sp

6: sp <- subi sp, 16

7: ; end prologue
8: t0 <- 3

9: s0{8}[-16] <- t0

10: t0 <- s0{8}[-16]

11: t0 <- t0
                                                                                                                                                  8: t0 <- 3
                                                                                                                                                  9: s0{8}[-16] <- t0
                                                                                                                                                  10: t0 <- s0{8}[-16]
11: t0 <- t0
12: s0{8}[-8] <- t0
13: t0 <- s0{8}[-8]
14: a0 <- t0
                                                                                                                                                   12: s0{8}[-8] <- t0
                                                                                                                                                   14: a0 <- t0
 15: j main_1
                                                                                                                                                   15: j main_1
 16: main_1
                                                                                                                                                  16: main_1
17: sp <- s0
18: s0 <- sp{8}[0]
                                                                                                                                                  17: sp <- s0
18: s0 <- sp{8}[0]
 19: sp <- addi sp, 8
                                                                                                                                                   19: sp <- addi sp, 8
20: ra <- sp{8}[0]
21: sp <- addi sp, 8
                                                                                                                                                  20: ra <- sp{8}[0]
21: sp <- addi sp, 8
22: jmpr ra
                                                                                                                                                  22: jmpr ra
```

(a) Pause d'un point d'arrêt.

(b) Point d'arrêt atteint.

FIGURE 9 – Quelques éléments de l'interface graphique du déboggueur LDB.



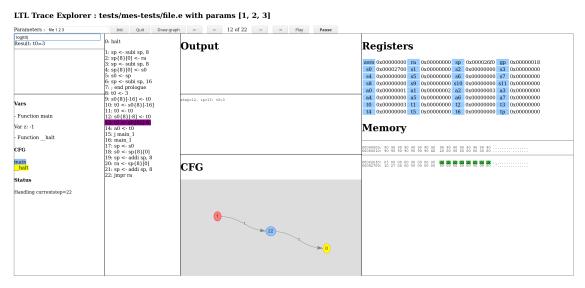


FIGURE 10 – L'interface du déboggueur LDB lors de l'utilisation de l'évaluation d'expression et des points d'arrêt.